大模型指导材料逆向设计

硕士论文选题比较与算法创新分析

日期：2026 年 10 月 15 日 ｜ 用途：选题讨论、开题前预研 ｜ 版本：1.0

阅读结论

优先考虑 A「校准决策与选择后风险优化」或 C「决策收益驱动的预算分配」。它们直接研究预测与选择之间的算法问题，与 Jev 强调的结构化决策相呼应，也能使用商业大模型 API，不必从零训练大模型。B「可靠知识先验与数值模型融合」是备选，但必须先证明大模型知识有独立增益。

如果更希望训练本地模型，考虑 E「面向决策质量的小模型蒸馏」，把贡献放在选择保持、可信度或数值结构上。D「物理约束生成与偏好优化」依赖可靠评价器；F「联合表征与潜空间逆向设计」对物理数据和验证要求最高，当前条件下不作为首选。

新颖度是做出文中所列增量后的潜力，不是已完成查新的原创性认证，也不是发表概率。调用 API、换模型、加入 LoRA、普通 RAG 或多智能体讨论，均不能单独作为算法创新。

1. 研究条件与判断标准

1.1 适用条件

研究者为计算机专业，可租 RTX 5090 等单卡算力，接受商业模型 API；剩余时间约一年；真实材料制备测试可能只能一次。材料体系未定，金属／合金是候选。本文件不依赖现有 RAG 知识库，知识库仅作为可选证据源。

这是选题比较文档，不是论文结果或系统查新报告。尚未开展模型训练、原始数据完整性审计和材料实验。文中的方法、最小实验与退出条件均为拟议设计。

1.2 逆向设计与证据层次

正向预测是给定成分或结构后预测性能；逆向设计是给定性能目标及约束，提出或选择成分、结构和必要工艺。只有性能预测器，不能称为完成逆向设计。

应区分：已有标签候选池上的隐藏标签回放，证明回溯筛选效率；训练集外新成分的独立可信计算，支持计算条件下的设计能力；真实制备测试，支持该候选在指定工艺下的实际表现。这三种证据不能互相替代。

1.3 新颖度和难度口径

新颖度采用定性判断：偏低、中等、中一较高潜力。依据是与已核实前作相比，是否改变学习目标、优化问题、可信度建模或信息获取机制。热点、模型规模和系统复杂度不自动带来新颖度。

难度综合考虑数学推导、数据、工程和验证依赖。「中等」仍需完成强基线与独立测试；「高」通常有一个关键前提尚未解决；「很高」意味着多个前提同时依赖。它不是 GPU 训练时长。

Jev 是 TypeSafe AI 的 System One 决策模型，官方强调结构化输出与校准决策。[1] 它不是 JEPA。本文借鉴决策接口思想，不假设可以复现其在已读资料中尚未充分公开的训练细节，也不把厂商指标当作材料实验结果。

2. 方向总览

方向	新颖度潜力	综合难度	当前建议
A 校准决策与选择后风险优化	中—较高	中高，统计推导较难	优先，适合重方法论文
B 可靠知识先验与数值模型融合	中等，机制需具体化	中高，知识增益不确定	次优先，API 友好
C 决策收益驱动的预算分配	中—较高	中高，离线评估较难	优先，算法与工程兼顾
D 物理约束生成与偏好优化	中等，普通 DPO 套用不足	高，评价器是关键	有独立验证器再选
E 面向决策质量的小模型蒸馏	中等，单纯微调偏低	中等，标签和校准需投入	本地训练路线首选
F 联合表征与潜空间逆向设计	中—较高，竞争强	很高，物理数据依赖强	不作为当前首选

选一个主方向，最多配套另一个方向的一个机制。不要同时做六条线；一个完成度高的中等新颖度方向，可能比高风险方向更适合硕士论文。

3. 方向 A：校准决策与选择后风险优化

3.1 问题、输入与输出

问题：模型在普通测试集上概率较准，优化器挑出高分候选后，这些候选的概率是否仍可信？在成分分布变化和标签稀缺时，怎样限制失败风险，同时保留有效推荐？

输入是目标、候选成分／结构及工艺、已有真实标签和验证预算。输出是联合达标概率、是否额外验证的决策与最终推荐集合。低成功概率不等于没有探索价值，应区分预测与决策。

3.2 算法创新落点

A1：面向联合达标事件学习与校准。直接建模多个目标同时满足的概率，或显式处理约束依赖，不能简单相乘边际概率。重点评价被选中候选的误差，而不只优化整体精度。

A2：把选择策略与风险控制耦合。可从有限候选池出发，设计随机化选择策略，约束其相对校准参考分布的偏移，在风险、批次多样性与推荐数量之间求解。增量应是新的可计算约束或求解机制，而非固定概率阈值。

先明确风险是随机推荐的平均失败、批次失败数量，还是至少一次失败的概率。风险定义不同，算法和保证也不同。

3.3 已有工作与新颖度

概率校准、保形风险控制、反馈分布偏移与安全优化均已有前作。[8–10,17] Fannjiang 等已经研究设计中的反馈协变量偏移。[9] 因此「材料设计＋保形预测」本身不够新。

有价值的增量是：在明确选择机制和风险定义下，得到更有效的批次风险估计或更少保守的优化方法，并与现有方法直接比较。潜力中一较高，能否形成理论贡献取决于推导。

3.4 难点、最小实验与退出条件

难点是选择后依赖、小校准集和分布变化。普通保形覆盖率不自动等于推荐集条件失败率；任意未知体系外推也没有无条件保证。无法证明时称为「风险感知」，不能写成「风险保证」。

最小实验：固定候选池与底座，对比未校准、温度缩放、适用的保形／反馈偏移方法及新策略；按来源与近似成分分组，评价推荐数量、有效命中、推荐集失败率与概率误差，增加体系外测试。

退出条件：若所谓风险下降仅因几乎不再推荐，或固定预测器后新策略不优于已有方法，应重审贡献。只提高分类精度，不足以完成本方向。

建议题目：《面向小样本合金逆向设计的选择后风险校准与约束优化方法》。

4. 方向 B：可靠知识先验与数值模型融合

4.1 问题、输入与输出

问题：商业大模型的材料知识可能错误、过时或不适用于当前工艺。标签稀缺时，怎样利用正确知识，又避免错误先验带偏搜索?

输入为任务描述、允许使用的知识、真实历史标签与候选；输出为知识局部可信度、融合预测和知识引导的候选。没有 RAG 也可使用固定资料包或结构化询问，但对照需遵守相同信息规则。

4.2 算法创新落点

B1：学习知识的局部适用性。利用成分与工艺匹配、与真实观测的冲突、来源依赖，估计先验在哪些区域可用，并随合法获得的反馈更新。大模型自报置信度只能作特征，不能直接当校准概率。

B2：设计错误先验下可恢复的融合与搜索机制。限制先验对搜索分布的影响；持续冲突时主动降权或验证。研究能否用更少观测识别局部失效先验，并避免负迁移。

简单加权只能称为预测融合；没有严格推导不能称为贝叶斯后验。知识与训练数据可能相关，不能重复计算证据。

4.3 已有工作与新颖度

LLAMBO 已研究大模型辅助优化初始化、代理预测和候选采样。[6] 语言模型用于小样本材料预测也有前作。[2] 「API 先验＋贝叶斯优化」新颖度偏低。

需要新增可学习的局部可信度、错误先验适应机制或来源依赖处理。换提示词、固定权重融合和增加检索不足以成立。整体潜力中等，具体机制与理论充分时可提高。

4.4 难点、最小实验与退出条件

关键前提是大模型确实提供真实标签之外的信息，而非记住测试答案。需按来源隔离，区分公开材料回溯与新候选设计，并披露 API 预训练污染无法完全排除的限制。

最小实验：比较无先验、固定先验、普通融合与学习可信度；增加明确标注的错误先验压力测试，观察负迁移、纠错所需观测及最终发现。人工压力测试不能被写成真实材料规律。

退出条件：API 相对强数值模型无额外增益，或收益来自测试答案泄漏时，停止扩大系统，可转 A／C。

建议题目：《面向合金逆向设计的局部知识可信度学习与稳健先验融合》。

5. 方向 C：决策收益驱动的预算分配

5.1 问题、输入与输出

问题：哪个候选值得继续研究？应该调用强模型、补证据还是计算验证？动作价值能否由它对最终材料选择的改善来衡量？

输入为候选、当前模型状态、各类查询费用、剩余验证次数与历史反馈；输出为「候选—信息动作」及最终推荐。难题不一定值得花钱，一个接近推荐边界且缺关键证据的候选可能更重要。

5.2 算法创新落点

C1：学习最终发现收益的信息价值。用训练任务离线回放估计「执行动作后最终有效发现预计改善多少」。可先在小训练任务记录各动作结果；反事实结果不完整时，需要明确的离线策略评估假设，不能访问测试标签训练路由器。

C2：联合分配查询和验证预算。API 观点、文献证据、物理计算是不同观测类型，使用不同更新机制。结合剩余预算、候选位置、模型分歧与收益选择动作。可从单步决策或上下文赌博机开始，再决定是否需要多步强化学习。

上下文赌博机指根据当前状态选一次动作，再从反馈学习其收益。新意应在材料选择收益与异质观测的处理，「收益除以费用」公式本身没有新颖性。

5.3 已有工作与新颖度

FrugalGPT、RouteLLM 已研究成本与回答质量间的级联／路由。[11,12] 多保真优化已利用便宜近似加速昂贵评价。[13] 改名为材料智能体不构成创新。

潜在差异是优化最终发现而非回答偏好，联合选择材料与动作，明确语义判断不是物理真值。若提出有效收益估计与预算求解机制，具有中—较高潜力。

5.4 难点、最小实验与退出条件

难点是收益延迟、日志只记录被选动作，以及不同观测不满足统一保真度假设。API 查询费用、计算费用和真实验证次数应分开约束；不能让一种方法额外获得更多真值。

最小实验：对比全量强 API、随机动作、固定级联、不确定性阈值、适用的成本感知优化与新策略；分别报告同标签预算和同费用上限的结果，预计算也计费，另做跨 API 与跨体系测试。

退出条件：若只减少调用但明显损失发现质量，或不优于固定阈值，不把路由器包装成主要成果。

建议题目：《面向合金逆向设计的决策价值估计与预算自适应信息获取》。

6. 方向 D：物理约束生成与偏好优化

6.1 问题、输入与输出

问题：给定目标，语言模型怎样生成满足成分和工艺约束的候选？评价器会出错时，怎样防止生成模型专门迎合评价器？

输入为目标、约束、已有材料与可靠评价；输出为新成分／结构及必要工艺。元素范围与成分总和可由程序检查，真实相形成和性能仍需独立验证。

6.2 算法创新落点

D1：不确定性感知的偏好构造。比较候选时结合评价误差与置信区间，难分高下时不强行标胜负；研究软偏好或拒绝比较如何进入训练目标。

D2：可行域与多样性保持的生成优化。研究可行域内编辑、评价不确定性约束的更新，以及防止近重复生成的探索机制，与生成后修复和标准偏好优化逐项比较。

DPO 是使用偏好对训练模型的方法，已有前作。[14] 使用可验证奖励时要说明验证的是格式、数值约束还是物理性能，不能混称。

6.3 已有工作与新颖度

文本生成晶体、条件扩散和语言模型辅助合金设计均已有研究。[3–5] 「DPO／强化学习用于材料」属于方法迁移，潜力中等。需要针对偏好噪声、可行域或评价器被利用的问题提出方法。

6.4 难点、最小实验与退出条件

最关键的资源是独立评价器。同一代理模型同时提供奖励和最终结论，不能证明材料改进。需要独立标签或可信计算，并排除对训练材料的近重复。

最小实验：标准条件生成、标准 DPO、生成后筛选／修复与新目标，在相同验证预算下比较可行率、独立达标率与多样性。梯度训练需开源模型或供应商支持的微调接口，普通 API 调用不能改变模型权重。

退出条件：拿不到独立验证依据，或只提高代理分数时暂缓。增加大模型互评次数不能替代物理验证。

建议题目：《面向合金逆向设计的不确定性感知偏好学习与约束生成》。

7. 方向 E：面向决策质量的小模型蒸馏

7.1 问题、输入与输出

问题：能否将强 API 与真实反馈的知识压缩到本地小模型，并保持候选排序、可信概率和推荐边界上的决策能力?

输入为目标、成分和工艺、真实标签及核验过的教师输出；输出为分类、联合达标概率、排序或转交强模型的决策。它与 Jev 的结构化决策思想联系直接，但不宣称复现 Jev。

7.2 算法创新落点

E1：决策损失驱动的蒸馏。除真实标签监督，重点保持靠近推荐边界的排序与选择收益，减少重要候选被错误淘汰；与普通答案模仿、软标签蒸馏比较。

E2：可信度与数值结构保持。联合编码成分数值与工艺文本，处理成分书写顺序等价性；在真实标签上重新校准，区分学生对教师的忠实度和对材料真值的正确率。

商业 API 通常不提供完整内部 logits，应使用实际可取得的结构化输出、比较或采样统计。教师生成数据不是新增真实材料标签。

7.3 已有工作与新颖度

蒸馏、参数高效微调和语言模型合金预测均有前作。[2,15,16] 只用 LoRA／QLoRA 微调，新颖度偏低。改变决策保持目标并证明独立效果，可具有中等潜力。

7.4 难点、最小实验与退出条件

难度相对可控，但需要可靠且多样的任务。纯成分表上，树模型或小型专用模型可能更强；必须证明文本或预训练信息的价值。单卡可行性需按模型、长度和批量实测，不能承诺固定训练时长。

最小实验：强教师、纯监督小模型、普通蒸馏、新方法与数值基线，对比材料选择、概率误差、延迟、显存和累计费用；不能套用 Jev 宣传速度。

退出条件：优势仅是回答更短，或专用模型已达到相同质量时，应缩小模型或重新定位贡献。

建议题目：《面向材料逆向设计的任务条件决策蒸馏与校准小语言模型》。

8. 方向 F：联合表征与潜空间逆向设计

8.1 问题、输入与输出

问题：学习成分、结构和性能的联合表示后，能否在表示空间按目标寻找候选，并可靠还原为物理可行材料？它关联多模态表示、扩散／流式生成与物理基础模型。

输入为成分—结构—性能配对数据，可能还需能量和原子力；输出为目标结构、构型或成分。有序晶体、无序合金和工程微观组织是不同对象，不能互换。

8.2 算法创新落点

F1：保持等价性和目标相关性的联合表示。处理成分顺序、周期对称性或无序构型，使表示支持目标搜索，而非只提高预测精度。

F2：可行域内潜空间搜索与还原。约束潜空间更新，避免高预测分区域不能解码、物理不合理或远离数据支持；用独立能量／性能计算检查结果。

语言模型接现成生成器仍需证明新增表示或搜索机制有效，组件数量不构成创新。

8.3 已有工作与新颖度

Crystal-LLM、MatterGen、JANUS 已涉及文本生成、条件扩散及无序材料采样设计。[3–5] 仍有算法空间，但基线与物理验证要求较高。未完成全面查新，仅给出中—较高的有条件潜力判断。

8.4 难点、最小实验与退出条件

很高难度来自配对数据、结构表示、模拟工具和独立验证同时不可缺。API 不能替代结构数据与能量评价；无序合金还涉及构型、温度和相变。

最小范围应限于一个结构家族或少元素体系，复用适用的预训练物理模型，在相同评价预算下比较标准条件生成、无潜空间搜索和新方法。

退出条件：初期没有匹配数据、势函数／评价器，或跑不通可信计算基线时，不扩大为通用材料基础模型。

建议题目：《面向受限材料体系的结构—性能联合表示与可行潜空间逆向设计》。

9. 当前条件下的推荐组合

9.1 优先：A 为主，C 的一个机制为辅

题目可用《面向小样本合金逆向设计的校准决策与预算约束优化》。集中做选择后风险估计或风险约束求解，再研究何时额外验证。API 可提供候选或辅助判断，但需消融证明作用。

范围限定为一个任务、一个风险定义、一项选择算法和适用的独立验证。不同时承担任意分布保证、多步强化学习、多模态知识库和从零结构生成。

9.2 API 优先备选：B 为主，C 的查询价值为辅

题目可用《大模型知识增强的合金逆向设计：可信先验与预算自适应决策》。先证明知识增益，再处理局部失效先验。主要风险是知识无额外价值，不是模型不够强。

9.3 本地训练备选：E 为主，A 的一个校准机制为辅

题目可用《面向合金逆向设计的决策保持蒸馏与校准小模型》。成果应体现在蒸馏目标、选择保持或等价表示，不只展示问答。

不建议 D 与 F 组合为首年主线，会叠加生成、表示与可靠物理评价的风险。也不把「通用自主材料科学家」作为初始范围。

10. 材料与实验的共同约束

10.1 材料体系

金属是否容易，取决于数据与制备合作。可先考虑明确工艺下的相形成／玻璃形成，再加原料成本。强度—塑性联合设计必须有对应的工艺与测试条件，不能混合不同样品状态。

matminer 官方目录列出 matbench_glass 5,680 条、matbench_steels 312 条等数据。[18] 这是目录规模，不代表去重和分组后仍有同样多有效样本。多主元合金相形成可从 [2] 获取基线和数据线索，下载、许可、工艺和标签定义仍待审计。

热力学计算需核实数据库适用范围；平衡相不能直接替代非平衡制备与实际强度测试。

10.2 公平对比与独立评价

预测层至少包含强数值模型；优化层包含随机选择、适用的约束贝叶斯优化及任务前作。[7] 研究 API 引导时加入 LLAMBO 类对照。[6] 不必运行所有文献算法，但要说明适用性。

固定候选范围、初始标签和预算。分别报告同真值访问预算和同费用比较，费用包括教师数据、预计算、失败调用与验证，不能把额外标签藏进提示词。

按文献、近似成分或结构家族分组，设置与主张一致的体系外测试；调参、校准、盲测尽可能独立。使用多随机种子和适合分组数据的区间估计，不只报最好一次。

主指标为有效发现、最终达标率、失败代价及适用的最优值／超体积。概率模型另报 Brier／负对数似然与选择后校准；生成模型另报可行性、新颖性和多样性。文本流畅、大模型互评或引用正确不能代替材料结果。

10.3 一次真实实验

主要算法证据来自充分隔离的离线回放和适用的独立计算。真实实验在方法冻结后进行，提前固定候选、工艺和成功标准；若允许一批次争取含对照，只有一个样品则限定案例结论。

单次成功不能证明概率已校准，单次失败也不独立否定算法。若学校要求真实的新材料发现，回溯筛选不能单独满足，应提前与导师统一证据标准。

11. 一年安排与预研决策

阶段	产出	决策标准
第 1 个月	数据审计、任务定义、强基线、针对性查新	标签可用，关键前提没有失败
第 2—4 个月	一个核心方法与单模块消融	固定其他组件后仍有稳定增益
第 5—8 个月	完整算法、预算和跨体系实验	不是泄漏、额外标签或偶然结果
第 9—10 个月	冻结方案、有限真实验证	候选可制备，标准预先固定
第 11—12 个月	论文、复核、答辩与复现材料	主张和实际证据一致

A 先验证风险控制后仍保留有效推荐；B 先验证知识增益；C 先验证不同动作的价值确有差异；D 先拿到独立评价器；E 先验证小模型相对专用基线的必要性；F 先跑通物理基线。关键前提失败时切换或收缩任务，不靠扩大系统掩盖问题。

12. 代表文献与核验范围

以下来源在本轮及此前会话中已打开官方、期刊、会议或 arXiv 页面核实存在；不是完整综述。部分只读摘要，未复现。通用搜索与部分 arXiv 检索遇到 429 限流，最新相近工作仍待补查。经典前作不等于当前最强基线。

[1] TypeSafe AI. Introducing System One Models & Jev，2026-09-15；及 Introduction、Confidence 官方文档。已读发布与接口说明；厂商资料，非同行评审算法论文。

https://typesafe.ai/blog/introducing-system-one-models-and-jev

https://docs.typesafe.ai/introduction

https://docs.typesafe.ai/confidence

[2] Jablonka, K. M., et al. Leveraging large language models for predictive chemistry. Nature Machine Intelligence 6, 161–169, 2024. DOI: 10.1038/s42256-023-00788-1。已读摘要和正文主要方法／结果。

https://www.nature.com/articles/s42256-023-00788-1

[3] Gruver, N., et al. Fine-Tuned Language Models Generate Stable Inorganic Materials as Text. ICLR 2024. DOI: 10.48550/arXiv.2402.04379。摘要、书目和代码链接核实，未复现。

https://arxiv.org/abs/2402.04379

[4] Zeni, C., et al. A generative model for inorganic materials design. Nature 639, 624–632, 2025. DOI: 10.1038/s41586-025-08628-5。已读主要正文；MatterGen。

https://www.nature.com/articles/s41586-025-08628-5

[5] Blessing, D., et al. JANUS: A Multi-modal Foundation Neural Sampler for Disordered Materials. 2026 年预印本。DOI: 10.48550/arXiv.2608.19116。已读摘要、引言和部分方法。

https://arxiv.org/abs/2608.19116

[6] Liu, T., et al. Large Language Models to Enhance Bayesian Optimization. ICLR 2024. DOI: 10.48550/arXiv.2402.03921。已读主要方法和实验设置；LLAMBO。

https://arxiv.org/abs/2402.03921

[7] Gelbart, M. A., et al. Bayesian Optimization with Unknown Constraints. 2014. DOI: 10.48550/arXiv.1403.5607。摘要与书目核实。

https://arxiv.org/abs/1403.5607

[8] Guo, C., et al. On Calibration of Modern Neural Networks. ICML, PMLR 70:1321–1330, 2017。会议页摘要与书目核实。

https://proceedings.mlr.press/v70/guo17a.html

[9] Fannjiang, C., et al. Conformal Prediction Under Feedback Covariate Shift for Biomolecular Design. PNAS 119(43), e2204569119, 2022. DOI: 10.1073/pnas.2204569119。已读问题定义、主要理论设定和部分方法。

https://arxiv.org/abs/2202.03613

[10] Angelopoulos, A. N., et al. Conformal Risk Control. 2022 年首次预印本，页面有后续修订。DOI: 10.48550/arXiv.2208.02814。摘要与书目核实，未逐条审计定理条件。

https://arxiv.org/abs/2208.02814

[11] Chen, L., Zaharia, M., & Zou, J. FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance. 2023 年预印本。DOI: 10.48550/arXiv.2305.05176。摘要与书目核实。

https://arxiv.org/abs/2305.05176

[12] Ong, I., et al. RouteLLM: Learning to Route LLMs with Preference Data. 2024 年首次预印本，后续有修订。DOI: 10.48550/arXiv.2406.18665。摘要与书目核实。

https://arxiv.org/abs/2406.18665

[13] Kandasamy, K., et al. Multi-fidelity Bayesian Optimisation with Continuous Approximations. ICML, PMLR 70:1799–1808, 2017。会议页摘要与书目核实；BOCA。

https://proceedings.mlr.press/v70/kandasamy17a.html

[14] Rafailov, R., et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. 2023 年首次预印本，后续有修订。DOI: 10.48550/arXiv.2305.18290。摘要与书目核实。

https://arxiv.org/abs/2305.18290

[15] Dettmers, T., et al. QLoRA: Efficient Finetuning of Quantized LLMs. 2023. DOI: 10.48550/arXiv.2305.14314。摘要与书目核实。

https://arxiv.org/abs/2305.14314

[16] Hinton, G., Vinyals, O., & Dean, J. Distilling the Knowledge in a Neural Network. arXiv, 2015；页面注明 NIPS 2014 Deep Learning Workshop。DOI: 10.48550/arXiv.1503.02531。摘要与书目核实。

https://arxiv.org/abs/1503.02531

[17] Sui, Y., et al. Safe Exploration for Optimization with Gaussian Processes. ICML, PMLR 37:997–1005, 2015。会议页摘要与书目核实；保证依赖指定假设。

https://proceedings.mlr.press/v37/sui15.html

[18] matminer 官方文档：Table of Datasets。已读目录与部分字段说明，未下载审计原始数据。

https://hackingmaterials.lbl.gov/matminer/dataset_summary.html

13. 阅读顺序与待定事项

先读 [2] 和 [6]，明确微调材料预测和 LLM 优化已有基础；选择 A 再精读 [8–10,17]，选择 C 精读 [11–13]，选择 D／E 进入 [14–16]，选择 F 才系统进入 [3–5]。

待定事项是具体材料体系、实际标签与工艺字段、实验合作能力、API 与 GPU 费用上限，以及导师认可的验证层次。它们影响最终范围，但不妨碍先比较方向。本文件不锁定任何一个方案。

建议下一步只保留最多两个方向，以真实可用数据检验关键前提后，再确定一个主方向。

本文由 AI 辅助整理。文献存在性核验、局部原文阅读、算法构想和新颖度评估是不同工作；本文不代表完成人工同行评审、全面系统查新或实验验证，不承诺某方向必然发表。