北京科技大学

硕士学位研究生

选题报告及文献综述

论文题目：基于本体约束与可校准决策模型的材料合成路线文献可行性预测研究

指导教师：艾冬梅

单　　位：数理学院

姓　　名：唐宁俊

学　　号：M202410824

专业名称：统计学

入学时间：2024 年 9 月 5 日

2025 年 12 月

目　录

1 选题背景及选题意义

1.1 选题背景

1.2 选题意义

2 文献综述

2.1 材料合成路线推荐方法综述

2.2 大模型不确定性校准方法综述

2.3 现有研究的局限性

3 研究内容、研究方案、时间安排

3.1 研究内容

3.1.0 预测目标的界定与标签口径

3.1.1 基于本体约束的合成可行性决策空间构造

3.1.2 决策模型的领域知识注入与自动训练

3.1.3 文献可行性的概率校准与证据可靠性分层

3.2 研究方案

3.3 时间安排

4 研究的局限性

参考文献

1 选题背景及选题意义

1.1 选题背景

材料是国民经济与国防安全的基础，其研发周期直接决定高端制造的迭代速度。美国“材料基因组计划”（Materials Genome Initiative，2011）提出以计算、实验与数据三位一体的方式将新材料研发周期缩短一半；欧盟“地平线欧洲”、日本“材料纳米技术计划”以及我国《“十四五”原材料工业发展规划》《新材料产业发展指南》均将材料数据的智能化利用列为重点方向。在新一轮人工智能加速科学发现（AI for Science）的国际竞争中，如何让大模型可靠地服务于材料研发，已成为衡量一个国家科研基础设施智能化水平的重要标志。

材料研发的核心瓶颈正在从“发现候选”转向“验证候选”。高通量计算与生成模型已经能够产出海量候选结构，但文献明确指出，被预测为稳定的物相中最终被实验实现的比例不足百分之二[1]。换言之，当前真正稀缺的不是候选，而是“这个候选能否被做出来、该怎么做”的可靠判断。合成路线推荐因此成为连接计算预测与实验实现的关键环节。

大语言模型为合成路线推荐提供了新的技术路径。基于文本挖掘的合成配方数据集使模型可以从文献中学习“目标材料—前驱体—工艺条件”的对应关系；检索增强生成（Retrieval-Augmented Generation，RAG）与轻量微调（Low-Rank Adaptation，LoRA）使领域知识的注入成本大幅降低；以 Jev 开创的 System One 决策模型[2]为代表，语言模型可被改造为不生成自由文本、仅输出带概率的类型化判断，其开源实现 Laya[3] 参数规模约四亿，从结构上规避了幻觉。

然而，现有材料合成路线推荐系统普遍存在一个被其作者明确承认、却尚未解决的缺陷：系统输出的是单调排序分数，而非校准过的成功概率。这意味着下游使用者无法依据该分数做出风险决策——无法判断“0.7 分”究竟对应七成成功率还是三成成功率。在实验资源极其昂贵的材料研发场景中，这一缺陷直接削弱了推荐系统的实用价值。

1.2 选题意义

理论意义：本课题研究如何在本体约束下，把大模型的类型化判断转化为具有覆盖保证的概率输出。这一问题的本质是“结构化决策空间上的不确定性校准”，属于统计学习与知识表示的交叉问题。将其置于材料合成这一具有明

确约束的场景中，可为校准理论在有限样本与分层结构下的推广提供新的实证基础。

方法意义：本课题提出以本体约束替代自由生成、以可校准概率替代排序分数的技术路线。该路线不依赖大模型的参数规模，而依赖输出空间的结构化设计与概率的统计建模，因而在单卡算力条件下即可实现，为资源受限环境下的领域大模型应用提供可复用的方法框架。

应用意义：本课题面向材料研发中“合成可行性判断”这一真实瓶颈。经校准的置信度可为实验排产提供概率依据：在明确成本—收益规则后，可据此判断是否值得追加一次表征、是否应改换候选。其价值主要体现在阈值型取舍与拒答判断上，而非单纯改善候选排序——本文将在实验中专门检验这一区分。对于以试错法为主、单次研发周期长达十余年的材料行业，具有直接的工程价值。

2 文献综述

2.1 材料合成路线推荐方法综述

材料合成路线推荐（Materials Synthesis Planning，MSP）旨在为目标材料推荐前驱体、合成操作与工艺条件。早期方法以启发式规则与专家系统为主，依赖人工整理的化学规则库，覆盖面窄且难以迁移。随着文本挖掘技术成熟，Kononova 等构建了大规模固态合成配方数据集，将文献中的非结构化描述转化为可计算的“配方编码”，为数据驱动方法奠定了基础[4]。

近年来的主流方法是基于语言模型的配方预测。Prein 等证明，未经任务微调的通用大模型已能回忆合成条件，在留出集上前驱体 Top-1 准确率可达 53.8%，Top-5 达 66.1%，且大模型集成可降低单次预测推理成本最多 70%，其训练的 SyntMTE 模型进一步将烧结温度预测平均绝对误差降至 73 摄氏度[5]。在此基础上，MSP-LLM 提出了统一的合成规划框架，将前驱体预测与操作序列预测纳入同一模型[6]；Retrieval-Retro 引入检索机制辅助无机逆合成，将专家知识以检索方式注入[7]。

更进一步的工作开始关注“条件”与“资源”两个维度。CondMSP 指出，已有方法仅把工艺条件作为预测目标，而未将其作为构建路线的过程上下文，也未回答“在有限实验资源下应优先执行哪些候选路线”。该工作将条件同时

用作上下文与执行要求，并在熔炉预算约束下以约束优化联合选择路线、分配热处理阶段，将参考配方恢复率从 27.9% 提升至 32.9%[8]。

在多源知识融合方面，Ha 等提出以 Dempster-Shafer 证据理论融合计算数据与从文献中由大模型抽取的领域知识，用于高熵合金相稳定性预测[9]。ProvMind 则从溯源角度出发，构建了基于文献挖掘过程图的推理框架，在时间与材料类别双重分布偏移下取得 52.84% 的准确率[10]。Materealize 进一步将结构生成、性质预测、可合成性预测与合成规划编排为端到端的多智能体系统，通过自然语言接口使非专家可使用计算材料工作流[11]。

国内研究同样沿着数据驱动方向推进。在材料基因组工程推动下，国内团队系统开展了材料信息学与机器学习辅助设计方法研究，在合金设计、配方挖掘与数据库建设方面积累了大量工作[12]；针对高熵合金等典型体系，已有研究将特征工程与集成学习结合，建立了成分—工艺—性能的映射模型[13]。

2.2 大模型不确定性校准方法综述

大模型的输出概率通常存在系统性偏差，即模型自报的置信度与其实际正确率不匹配，且偏差方向并不固定。温度缩放（Temperature Scaling）通过单一温度参数校正 logits，方法简单且在小样本校准上表现稳健。保形预测（Conformal Prediction）则从分布无关的角度出发，通过构造预测集使真实值以不低于名义水平 $1-\alpha$ 的边际概率被覆盖，为不确定性提供有限样本保证[18]；它保证的是覆盖率而非概率数值本身的准确性，与温度缩放等校准方法所解决的问题不同[19]。将二者混用，是当前应用中常见的误解。

在决策模型方面，Jev 开创了“类型化决策”范式：模型不生成文本，而是回答答案空间受约束的题目，并输出概率[2]。随后出现的开源实现 Laya（约四亿参数）证明该范式可在 CPU 上运行[3]。Geuter 等进一步证明，现有开源指令微调模型无需额外训练，仅通过读取末位 token 上选项字母的 logits 即可达到接近商业模型的决策性能[14]。

值得特别注意的是，校准偏差的方向必须由实测确定，不能预设。针对 Laya 的独立复现研究[15] 发现，该模型呈现一致的**置信度偏低**（signed gap 为 −0.214，每个可靠性分箱的准确率均高于置信度），与模型卡所暗示的“过度自信”方向相反；单一温度参数 T=0.469（即锐化）即可将留出集期望校准误差从 0.204 降至 0.037。这一结果说明：直接照搬“温度缩放用于降温”的做法可能南辕北辙，校准方向必须基于验证集实测。该研究同时指出，其冻结的

选择规则因采用保序回归而在留出集上过拟合，未能通过对比检验——这提示小样本条件下拟合方式的选择本身即是统计问题。

在材料领域，校准研究主要集中在势函数与图神经网络的性质预测上。CrystalJev 首次将校准概率引入材料发现决策，用冻结势模型的一次前向传播输出校准概率与保形保证，并据此决定是否将候选升级至弛豫或密度泛函计算；该工作通过 2,100 次密度泛函计算的前瞻性注册测试，验证了跨分布偏移下校准会高估稳定比例 0.9 至 2.2 个百分点[16]。

2.3 现有研究的局限性

综合上述文献，当前研究存在四方面明确局限，且前三条多为原作者在论文中主动承认。

第一，输出分数缺乏校准。CondMSP 在附录中明确写道，其经 Noisy-OR 融合得到的结果“仅是单调排序分数，未被当作校准过的成功概率，也未施加证据源独立性假设”[8]。这意味着该分数不具备概率语义：它可用于按优先级排序，却无法直接支撑以成本—收益为目标的取舍（例如在给定实验预算下，比较“追加一次表征”与“直接合成”的期望收益）。需要说明的是，对二分类评分施加统一的单调变换并不改变排序本身，因此校准的价值不在于改善排序，而在于为阈值型决策提供可解释的概率依据。

第二，缺乏时序泛化验证。CondMSP 同时承认，其目标集合的划分“未建立时序留出，也未排除基础模型预训练数据的污染”[8]。对于以文献为训练来源的模型，若测试集材料在预训练阶段已被模型见过，则性能评估将系统性偏高。目前尚缺乏基于发表年份的严格时序验证。

第三，参考数据的质量未分层。CondMSP 指出其参考文献为“大模型自动抽取、未经专家裁定”[8]。不同来源、不同抽取质量、不同年代的配方证据被同等对待，缺少按证据可靠性分层的机制，容易使低质量证据污染最终排序。

第四，训练标签的含义与偏置未被正视。现有工作多以“文献中是否存在合成记录”作为监督信号，但该信号同时受两类偏置影响：其一为报道偏置，合成失败与低产率结果在材料文献中系统性缺失，使“未报道”被误当作“已证伪”[21][22]；其二为选择偏置，研究者倾向使用熟悉的前驱体与成熟路线，导致数据在化学空间上分布不均。近期在有机反应产率预测中已有工作证明，正例—无标签学习可在一定程度上校正此类偏置[23]，但材料合成领域尚未系统采用。若不加处理，“成功概率”实际学到的是“哪些材料更常被研究”。

第五，异构证据融合与同源精度升级未被区分。CrystalJev 的贡献在于对同一物理量的不同精度层级（前向传播→结构弛豫→密度泛函）按决策价值排序，其各层级共享同一物理真值，可信度具有天然的单调序[16]；而合成路线推荐面临的是文献、热力学计算与大模型判断等**异质证据源**，它们量纲不同、可靠性不同、且可能互相矛盾，不存在天然的单调序。现有工作尚未系统处理这一差异。

3 研究内容、研究方案、时间安排

3.1 研究内容

本课题以“把排序分数转化为可校准的成功概率”为主线，面向材料合成路线推荐任务，研究本体约束的决策空间构造、决策模型的知识注入与自动训练、以及概率校准与证据可靠性分层三个相互衔接的问题，最终形成一个在单卡算力条件下可运行的合成可行性判断方法。三个问题按递进关系组织：第一步，用本体把开放式生成任务改造为答案空间受约束的类型化判断，从结构上排除一类幻觉；第二步，以检索与微调双通道注入领域知识，并以热力学判据自动构造训练标签，解决专家标注稀缺问题；第三步，在有限样本与分层证据结构下建立概率校准，使输出具备覆盖保证，从而回答现有系统“只给排序、不给概率”的缺陷。整体目标是得到一个能对任一目标材料给出“合成路线 + 成功概率 + 置信区间”的系统，并在留出集上与现有排序式方法进行可复现的对照。

3.1.0 预测目标的界定与标签口径

本课题的预测目标是**文献报道意义上的合成可行性**，而非真实实验意义的一手成功率。这一界定必须先行明确，因为它决定了全部结论的适用范围。

设目标材料为 m、候选路线为 r，定义正例为“文献中存在该材料经由化学上等价的路线被成功合成的记录”，负例为“文献中不存在此类记录”。需要强调的是，**“文献未报道”不等于“实验失败”**：合成失败与低产率结果在材料文献中系统性缺失，这一现象已被多处研究指出[21][22]。因此本课题预测的是 $P(\text{文献可查证} \mid m, r)$，其准确表述为“该路线是否有文献证据支持”，而非“该路线在实验中能成功的概率”。

针对文献数据固有的两类偏置，本课题采取如下处理。**其一，报道偏置：**数据集中几乎只有正例。若直接以“是否有记录”作为二分类标签，负例实

为“未报道”而非“已证伪”，标准监督学习会产生系统性偏差。因此采用**正例—无标签学习**（Positive-Unlabeled Learning）框架[23]：将已报道记录视为正例，未报道者视为无标签样本，通过估计类别先验与调整损失函数，得到对“若该路线被尝试则会被报道”这一事件的概率估计。**其二，选择偏置**：化学研究者倾向使用熟悉的前驱体与成熟路线，导致数据在化学空间上分布不均。本课题在划分数据集时按元素体系分组，并在报告中明确给出各体系样本量与覆盖率，避免以少数高频体系的表现代表整体。

上述界定带来一个必须如实承认的限制：**本课题无法验证所估计的概率是否等价于真实实验成功率**。若后续获得实验记录，可将其作为独立验证集对概率估计做外部校验；在缺少此类数据时，论文结论严格限定在“文献证据支持的可行性”这一层面。这一限制将在局限性一节中重复申明。

3.1.1 基于本体约束的合成可行性决策空间构造

针对大模型自由生成配方易产生幻觉、且输出格式不稳定的问题，本课题研究如何以轻量本体（Schema）定义合成配方的合法答案空间，并将开放式生成任务分解为一组答案空间有限的类型化判断问题。

具体地，本体层定义合成配方的实体与约束：前驱体集合、温度、时间、气氛与产率。此处须区分两类约束，二者的可靠性与处理方式不同：

硬约束指必然成立的约束，违反即说明输出无效，例如数值类型与量纲合法、时间与温度为正、元素在各反应步骤中守恒、电荷守恒。这类约束可直接用于过滤。

软约束指通常成立但存在例外的经验规律，例如“前驱体在给定温度下应稳定”。必须指出，**该条件并非必要**：前驱体的分解或与容器的反应本身可能正是合成过程的组成部分，因此不能据此否定一条路线，只能作为降低先验权重的依据。软约束不参与过滤，而作为特征输入或先验项进入模型，其权重通过验证集学习确定。

需特别说明，标题所称“本体”在此处指向对合成配方概念体系的结构化描述——包括实体类型（材料、前驱体、工序、条件）、实体间关系（前驱体组成目标产物、工序施加于材料）以及可施加其上的逻辑约束（守恒、取值范围），而非仅指字段清单。决策层将生成任务改写为三类问题：选项型（从本体定义的有限前驱体类别中择一）、评分型（在有序尺度上评价前驱体合理性）、是非型（判断某路线是否有文献证据支持）。由于选项集由本体生成，模型在结构上无法输出未定义类别，从而排除一类幻觉。

本研究内容的关键在于本体的粒度和问题分解方式：粒度过细会导致问题数量爆炸且相互矛盾，过粗则无法有效约束输出。将通过消融实验确定最优粒度，并以自由生成作为对照，量化幻觉率的下降幅度。同时，多个判断问题之间的概率不得违背硬约束导出的逻辑关系。例如由元素守恒可推出：若某路线的前驱体组合无法提供目标产物所需的全部元素，则该路线必然不可行，其可行性概率必须为零；这类关系由本体自动导出并强制成立。反之，由软约束导出的关系（如“前驱体稳定性”与“路线可行性”）不具必然性，仅作为先验相关项参与联合推断，不强加为零。约束推理以逻辑规则表达，求取联合一致解，并以**硬约束违反率**作为评价指标；对软约束则报告其被违反的频次，用以检验经验规律本身的适用边界。

3.1.2 决策模型的领域知识注入与自动训练

针对材料领域标注数据稀缺、专家标注成本高昂的问题，本课题研究以检索增强与轻量微调相结合的知识注入方法，以及基于热力学判据的自动化训练数据构造方法。

知识注入采用双通道：检索通道从自建的两万余篇材料文献全文语料库中检索事实证据，提供具体材料的配方与条件（该语料库与下文用于监督信号的合成配方数据集是两个独立资源，前者供检索、后者供标注）；微调通道以决策模型为底座，采用 LoRA 进行轻量适配，使其掌握类型化问题的作答方式与本体的字段语义。两条通道分工明确：检索擅长事实但不能约束输出形式，微调擅长形式但不能可靠记忆长尾事实。

训练数据的自动构造是本部分的核心。拟以热力学计算作为客观裁判：对文献中给出的前驱体组合，计算其反应能量与相对凸包位置，将“热力学强力否定”与“热力学支持且文献佐证”两类样本自动标注为负例与正例；对“热力学不支持但文献报道成功”的灰色地带样本单独划出，不作为训练标签，而作为后续人工校验或强化学习信号。该设计避免了将不可靠判据当作真值，同时缓解了迭代训练中错误标注累积导致的性能退化。

需要说明的是，热力学判据本身并非绝对可靠：亚稳相与动力学控制相在热力学上可能被判为不稳定，却在实验中成功获得。为此，“强力否定”须设定明确阈值（例如相对凸包能量高于某一数值，具体取值通过敏感性分析确定），并对负例再按“文献中是否有人尝试合成”细分——已有尝试而失败的记录，其证据强度高于无人尝试的空白。主实验将同时报告不同阈值下的结果，以说明结论对该设定的稳健性。

微调成本方面，所选决策模型参数规模约四亿，采用 LoRA 后单轮训练显存需求约四吉字节、单卡耗时约四十分钟，可在单张显卡上完成多轮迭代，为消融实验与超参数搜索提供算力可行性。

3.1.3 文献可行性的概率校准与证据可靠性分层

针对现有系统输出排序分数而非校准概率的问题，本课题研究如何将类型化判断的概率输出校准为具有覆盖保证的成功概率，并按证据来源可靠性进行分层校准。

本部分须区分两类目标，二者不可互相替代。**第一类是概率校准**，目标是使输出的数值概率与其经验正确率相符，评价指标为期望校准误差、最大校准误差与 Brier 分数及其分解。**第二类是预测集覆盖**，目标是在给定置信水平下构造一个集合，使真实标签以不低于名义水平的边际概率落入其中，评价指标为经验覆盖率与平均集合大小。前者回答“这个数值可不可信”，后者回答“在多大置信度下可以排除哪些选项”，二者对应不同的下游用法：前者用于阈值型取舍，后者用于候选筛选与拒答。

据此，本课题的校准方案分两级。第一级为温度缩放，以验证集上的负对数似然为优化目标校正概率尺度，并**先由验证集实测确定偏差方向**（锐化或平滑），避免沿用“模型必然过度自信”的预设；该级只调整概率，不改变排序。第二级在上述概率基础上构造保形预测集，采用分裂保形（split conformal）方式，以留出校准集估计分位数。需要明确其保证的形式：保形预测提供的是**给定置信水平下的边际覆盖率下界**，它不意味着模型已具备高精度，也不直接给出单条路线的成功概率区间；在小样本条件下该保证仍成立，但预测集可能显著偏大而缺乏信息量，因此必须同时报告平均集合大小，不能仅以覆盖率衡量优劣。

证据可靠性分层针对文献证据质量参差的问题。拟依据证据的来源类型（大模型自动抽取、人工校验、热力学计算支持）、发表年份与抽取置信度，将证据划分为可靠性层级，并为每层单独估计校准参数。

此处存在一个必须正面处理的统计问题：分层会减少每层可用样本量，使各层独立估计的校准参数方差增大，保形预测集也因分位数估计不稳而变得过宽。需要澄清的是，**标准保形方法在满足可交换性、采用正确分位数时，其边际覆盖下界并不因样本减少而失效**，代价是集合变大、信息量下降。因此本课题不采用“分层后独立拟合”的朴素做法，而拟采用**分层贝叶斯/部分池化**建模：为各可靠性层级设定共同先验，使各层参数在共享与独立信息之间折中，

从而降低估计方差并缩小预测集。该建模需要明确给出参数先验形式、部分池化的收缩强度、可交换性假设的检查方式，以及时序偏移下覆盖率另行评估的方案。部分池化本身不自动恢复覆盖保证，其与保形构造的衔接方式（是用部分池化后的概率再做保形，还是直接在分层结构上构造分层保形集）需在实验中对比确定。

3.2 研究方案

本课题分为四个阶段推进。

第一阶段，数据准备与基线搭建。以公开的文本挖掘合成配方数据集[4]为基础（该数据集包含约三万条化学反应记录，由约九万五千段文献段落自动抽取，需注意“反应记录数”与“文献篇数”并非同一计量单位），清洗重复与缺失记录，统计发表年份分布，构建训练、验证与测试划分，并额外构造基于年份的时序划分用于泛化验证。同时搭建未经校准的排序基线，复现现有方法的排序指标，作为后续对照。

第二阶段，本体设计与决策空间构造。在领域文献调研基础上确定合成配方的字段与约束，编写轻量本体；设计字段到类型化问题的映射规则；以自由生成为对照，量化本体约束对幻觉率与格式合法率的影响；通过消融确定本体粒度。

第三阶段，知识注入与自动标注训练。构建文献检索通道与微调通道；实现基于热力学判据的自动标注流程，统计三类样本的分布比例并完成阈值敏感性分析；完成多轮训练并监控每轮指标，验证防退化机制的有效性；与单一通道方案进行消融对比。

第四阶段，校准与综合评估。实现温度缩放与保形预测，含偏差方向实测；建立分层贝叶斯校准模型并分析样本量、收缩强度与预测集大小的关系；在留出集与时序测试集上评测。

评估协议须防止信息泄漏，数据按以下关系隔离：训练集用于拟合决策模型；校准集仅用于拟合温度参数与保形分位数，与训练集不相交；测试集在全部超参数（含本体粒度、分层方式、收缩强度）冻结后才被使用，不参与任何选择。文献检索库按时间边界冻结，时序测试集所用文献的发表年份晚于训练集与检索库的上界。需要说明，年份划分可检验时间泛化，但不能单独证明基础模型在预训练阶段未见过这些文献，因此对所用基座模型须核查其训练数据的时间下界，并在结论中如实标注这一不确定性。

评估指标分四组报告：任务性能（Top-k 准确率、排序指标）、概率质量（期望校准误差、最大校准误差、Brier 分数）、预测集性质（经验覆盖率与平均集合大小）、决策效用（在明确的成本—收益规则下的期望收益）。特别地，须与“直接按未校准分数排序”的简单策略对比，以检验校准是否真正带来决策增益；若在校准不改变排序的前提下决策结果无差异，则应如实报告，并将结论限定为概率可解释性的改善而非决策改善。

需要说明的是，本课题以公开数据与计算验证为主，不包含自主实验合成环节。具有代表性的若干条推荐路线将送交合作实验室做合成尝试，作为案例性佐证而非统计意义上的验证；这一取舍已在局限性中说明。

技术路线可概括为：原始文献与配方数据 → 清洗与时序划分 → 本体定义与问题分解 → 检索与微调双通道知识注入 → 热力学裁判的自动标注与迭代训练 → 概率校准与证据分层 → 带置信度的合成路线推荐。整体流程如图 3-1 所示。

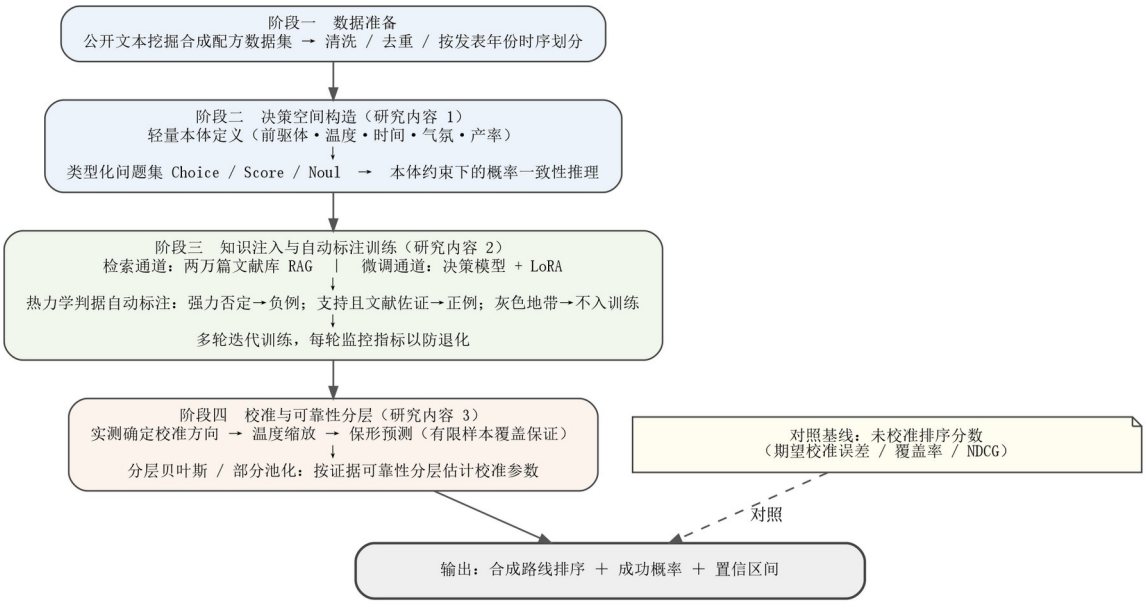


图 3-1　技术路线图

3.3 时间安排

2025.12 — 2026.03　文献调研与数据准备，完成公开数据集的清洗、时序划分与未校准基线搭建；

2026.04 — 2026.06　本体设计与决策空间构造，完成类型化问题分解并进行幻觉率对照实验；

2026.07 — 2026.09　检索与微调双通道实现，完成热力学自动标注流程与多轮训练，验证防退化机制；同期开展校准原型，与训练并行；

2026.10 — 2026.12　在校准原型基础上完成分层贝叶斯建模与保形预测，完成留出集与时序测试集评测；

2027.01 — 2027.03　结果分析与论文初稿撰写；

2027.04 — 2027.05　论文修改、定稿与答辩准备。

4 研究的局限性

本课题在设计上存在以下三项限制，须在正文与结论中如实申明。

其一，预测目标限于文献证据层面。 如 3.1.0 所述，本课题估计的是“该路线是否有文献证据支持”，而非真实实验成功率。二者不等价：文献未报道既可能源于实验失败，也可能源于无人尝试。因此论文不宣称所输出的概率可代表实验成功的可能性；若后续获得系统性的实验成败记录，可作为外部验证集检验该近似的程度。

其二，标签偏置只能部分校正。 报道偏置与选择偏置是文献数据的固有属性，正例—无标签学习可缓解但不能消除其影响。所估计的类别先验依赖于“未报道样本中正例比例”的假设，该假设无法用现有数据验证，只能通过敏感性分析给出其取值变化对结论的影响范围。

其三，实验验证为案例性而非统计性。 受资源限制，本课题不含系统性的自主合成实验。具有代表性的少数路线将送合作实验室做合成尝试，用于检查方法给出的高置信推荐在个案上是否合理，但样本量不足以支撑统计推断，不能作为模型有效性的定量证据。

参考文献

[1] Wang Y, Wu Z, Lu J, et al. Beyond structure: revolutionising materials discovery via AI-driven synthesis protocol-property relationships[J]. Journal of Physics: Materials, 2026. DOI: 10.1088/2515-7639/ae6e72. (arXiv:2605.00313)

[2] TypeSafe AI. Jev: a decision API for structured judgment (System One model), 2026. https://typesafe.ai

[3] Convai Innovations. Laya: an open-weights System One decision model, 2026. https://huggingface.co/convaiinnovations/laya

[4] Kononova O, Huo H, He T, et al. Text-mined dataset of inorganic materials synthesis recipes[J]. Scientific Data, 2019, 6: 203. DOI: 10.1038/s41597-019-0224-1

[5] Prein T, Pan E, Jehkul J, et al. Language models enable data-augmented synthesis planning for inorganic materials[J]. arXiv:2506.12557, 2025.

[6] Noh H, et al. MSP-LLM: A unified large language model framework for complete material synthesis planning[J]. arXiv:2602.07543, 2026.

[7] Retrieval-Retro: Retrieval-based inorganic retrosynthesis with expert knowledge[J]. arXiv:2410.21341, 2024.

[8] Noh H, Na G S, Pan E, et al. CondMSP: Condition-informed and resource-aware inorganic materials synthesis planning[J]. arXiv:2610.15603, 2026.

[9] Ha M Q, Le D K, Dao D A, et al. Synergistic fusion of multi-source knowledge via evidence theory for high-entropy alloy discovery[J]. arXiv:2502.14631, 2025.

[10] Zhang Y, Tamura R, Tsuda K. ProvMind: Provenance-grounded reasoning for materials synthesis[J]. arXiv:2605.28487, 2026. (npj Computational Materials, DOI: 10.1038/s41524-026-02303-7)

[11] Kim S, Choi J, Jang K, et al. Materealize: a multi-agent deliberation system for end-to-end material design and synthesis[J]. arXiv:2601.15743, 2026.

[12] 谢建新, 宿彦京, 薛德祯, 等. 机器学习在材料研发中的应用[J]. 金属学报, 2021, 57(11): 1343-1361.

[13] 文成. 基于机器学习的高熵合金成分设计与性能优化[D]. 北京科技大学, 2022.

[14] Geuter J, Cheng A, Alvarez-Melis D. Releasing the inner Jev: a simple recipe for open decision models[J]. arXiv:2610.17205, 2026.

[15] Laya as a typed probabilistic assessor: an independent reproduction and a preregistered study of calibration and selective escalation[J]. arXiv:2609.33843, 2026.

[16] Kang P, Sun Y, Li Z, et al. CrystalJev: calibrated foundation-model probabilities decide what to compute next in materials discovery[J]. arXiv:2610.06985, 2026.

[17] Zadrozny B, Elkan C. Transforming classifier scores into accurate multiclass probability estimates[C]//Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2002: 694-699.

[18] Angelopoulos A N, Bates S. A gentle introduction to conformal prediction and distribution-free uncertainty quantification[J]. arXiv:2107.07511, 2021.

[19] Guo C, Pleiss G, Sun Y, et al. On calibration of modern neural networks[C]//International Conference on Machine Learning. PMLR, 2017: 1321-1330.

[20] Gelman A, Hill J. Data analysis using regression and multilevel/hierarchical models[M]. Cambridge University Press, 2006.

[21] Failure case reporting in materials informatics: what is documented and what is silenced[J]. Journal of Artificial Intelligence for Materials Science, 2026.

[22] The treatment of absence and null results in materials machine learning literature: a review study[J]. 2026.

[23] Yield prediction of organic reactions in biased data sets via positive-unlabeled learning[J]. Journal of the American Chemical Society, 2026. DOI: 10.1021/jacs.6c00127