北京科技大学

# 硕士学位研究生

# 选题报告及文献综述

论文题目：标签不完整条件下材料合成路线文献支持度的概率校准策略研究


指导教师：艾冬梅

单　　位：数理学院

姓　　名：唐宁俊

学　　号：M202410824

专业名称：统计学

入学时间：2024 年 9 月 5 日


2026 年 10 月（修订）

# 目　录

1 选题背景及选题意义

1.1 选题背景

1.2 选题意义

2 文献综述

2.1 材料合成路线推荐与标签来源

2.2 概率校准、分层建模与保形预测

2.3 本课题拟解决的问题与现有方法边界

3 研究内容、研究方案、时间安排

3.1 研究内容

3.1.1 预测目标、候选分布与标签口径

3.1.2 约束决策空间与领域评分模型

3.1.3 概率校准策略、缺失实验与预测集构造

3.2 研究方案

3.3 时间安排

4 研究的局限性与预期成果

参考文献

# 1 选题背景及选题意义

## 1.1 选题背景

材料合成路线规划连接候选材料发现与实验实现。公开的文本挖掘数据已将文献中的目标材料、前驱体、操作及条件转化为结构化配方，为数据驱动规划提供了基础[1]。语言模型能够预测前驱体与热处理条件，统一规划框架进一步联合预测前驱体和操作序列[2][3]。然而，恢复已报道配方、判断热力学倾向与预测真实实验成败是不同任务，其标签和概率解释需要分别界定。

路线排序解决候选优先级问题，概率校准则研究数值置信度是否与所定义事件的经验频率相符。CondMSP 已在模拟熔炉预算下联合选择路线和分配热处理资源[4]，说明排序分数可以支撑资源约束优化；但排序表现并不能单独证明分数具有可靠的概率语义。若进一步使用阈值决定是否接受推荐或追加证据检索，就需要明确概率所对应的事件、候选分布和评价成本。

文献配方数据不是完整的实验尝试记录。库内没有匹配路线，可能意味着未尝试、未报道、尚未收录或抽取失败，不能直接解释为合成失败。材料领域也并非完全没有失败数据：Raccuglia 等已利用实验室历史失败记录预测特定体系的反应结果，并在论文页面提供补充反应数据[5]。这类记录的材料体系、实验条件和成功判据与通用固态配方数据不同，不能未经核验就直接合并。

本课题因此将主任务限定为固定参考语料中的路线匹配，称为“文献支持度”，并考察标签数量不足、观测机制变化和证据分组对校准策略的影响。该任务能够通过冻结参考库核验，不将文献支持度解释为真实合成成功率。

## 1.2 选题意义

**统计意义**：在同一底座评分和候选分布下，研究全局拟合、独立分组和部分池化在样本量与组间差异变化时的表现。区分概率误差、预测集覆盖和选择性决策风险，明确各指标所需的标签与假设。

**方法意义**：本课题定位为可复现的比较研究，不宣称提出新的通用校准算法。拟通过可核验的路线匹配基准与受控标签缺失实验，分析分组拟合的方差代价、部分池化的收缩偏差及失效情形。本体约束和领域知识注入作为固定的实验基础设施，不预设复杂模型或部分池化一定占优。相关方法是否已有同任务比较，仍需持续补充文献检索，不能据有限文献宣称“首次”。

**应用意义**：经验证的文献支持度可辅助选择待核验配方、分配文献复核预算，或提示模型拒答。对固定候选使用统一单调校准不改变排序，因此不承诺

提升固定 Top-k 的选择效果。实验排产收益需要真实实验成败记录和相应效用模型，本课题的离线结果不直接作此推断。

# 2 文献综述

## 2.1 材料合成路线推荐与标签来源

Kononova 等发布了自动抽取的固态合成配方数据，原始论文所述公开版本含 19,488 条合成记录，字段包括目标材料、前驱体、操作、条件及配平反应式[1]。记录数不等于论文数，不同发布版本的规模也不能混用。正式实验将固定下载版本、校验和及清洗脚本，再报告有效记录、唯一论文、字段缺失和人工抽查结果；目前不将未留存审计文件的统计量写成已完成成果。

Prein 等报告，未经任务微调的语言模型可回忆前驱体及合成条件，并通过数据增广改善专用模型[2]。MSP-LLM 将前驱体预测和操作序列预测统一为结构化过程[3]。CondMSP 进一步将温度、时间和气氛用于路线构造与执行约束，在每个目标三个模拟熔炉运行预算下，将参考配方恢复率由 27.9% 提升至 32.9%[4]。这些结果说明配方预测与资源约束规划具有研究基础，其参考恢复指标与真实合成成功率仍需区分。

Raccuglia 等利用包含失败尝试的实验室笔记研究钒亚硒酸盐体系的反应结果[5]，说明失败数据的价值，也说明任务范围必须与标签来源对应。本文将其作为独立外部验证资源的候选，先审计下载、字段、失败定义及许可，不预先承诺该资源足以支撑通用固态路线验证。

## 2.2 概率校准、分层建模与保形预测

概率校准要求预测值与所定义事件的经验发生频率一致。温度缩放利用正温度调整 logits，形式简单；带截距的逻辑校准还能表达基准发生率的偏移[6]。单一总体校准可能掩盖分组误差，而独立拟合又容易在小组中产生高方差。多层模型通过共享总体参数实现部分池化，但收缩程度和组间结构需要由数据与先验共同限定[11]。

保形预测构造包含真实标签的预测集合。在校准样本与新样本可交换、评分函数在保形校准前固定等条件下，分裂保形可提供有限样本边际覆盖下界[7]。它不是概率校准的替代品，也不自动给出单条路线成功概率的置信区间。样本少时，采用正确有限样本分位数仍可保持覆盖下界，但集合可能缺乏区分

能力；任意条件覆盖、每组覆盖及分布偏移下覆盖均不能由总体保证直接推出。

类型化决策模型从有限选项读取概率，可减少输出格式错误，但仍可能选择错误选项。Geuter 等研究了从现有指令模型末位 logits 读取选项概率的方法[8]。针对 Laya 的独立复现则报告了置信度偏低及温度缩放的改善，也报告了保序回归过拟合和分布外迁移限制[9]。因此校准方向与可迁移性都应由目标任务实测确定，不能由模型形式预先保证。

CrystalJev 将校准与计算升级决策结合，其前瞻性密度泛函计算测试仍观察到分布变化导致的概率偏差[10]。这为本课题区分同分布保证与时序压力测试提供了参考，不能据此推导材料合成任务已有相同保证。

## 2.3 本课题拟解决的问题与现有方法边界

本课题聚焦的问题是：在固定的文献匹配任务中，校准样本量、分组异质性和标签缺失机制如何影响校准策略的相对表现。研究假设为：小组独立拟合可能受方差影响；部分池化在一定组间差异与样本量范围内可能改善误差，也可能因过度收缩抹平真实差异。上述假设可由对照实验否证，不将某种方法必胜写入研究目标。

正例—无标签学习（Positive-Unlabeled Learning，PU）处理已知正例与混合无标签样本，其潜在类别概率的可识别性依赖类别先验、标注选择机制等条件[12]。如果预测目标只是固定库内是否匹配，该事件可直接核验，无需用 PU 重定义标签；如果目标改为潜在真实实验成功，则仅凭文献正例无法自动识别该概率。本文将 PU 保留为受控观测机制下的扩展比较，不把它作为绕过真实标签缺失的证明。

此外，化学约束只能检验候选结构或化学合理性，不能代替文献匹配标签；训练数据分组能够暴露部分泛化差异，也不能消除研究者选择偏置。概率校准、标签观测与候选生成必须在同一实验协议中定义，才能避免不同方法比较不同任务。

# 3 研究内容、研究方案、时间安排

## 3.1 研究内容

本课题以固态氧化物配方为首个研究范围，在冻结候选生成器、检索库和底座评分后，比较概率校准策略。主输出为“候选路线、文献匹配概率、标签

预测集合或拒答标记”。本课题不承诺覆盖任意材料，不把校准误差改善等同于合成成功率改善，也不预设全部候选都存在可恢复的参考配方。

### 3.1.1 预测目标、候选分布与标签口径

设目标材料为 m，候选路线为 r，参考语料快照为 R。主标签 Z_R(m,r)=1 表示路线在 R 中存在通过预先规定规则匹配的记录，Z_R(m,r)=0 表示在该快照中未匹配。“0”只代表库内未匹配，不代表实验失败。模型估计的是在指定候选生成与采样分布 Q 下的 P(Z_R=1 | 输入特征)，即文献匹配概率。改变 R、候选生成器或正负候选采样比例都会改变概率解释，必须重新验证校准。

主路线签名由规范化目标化学式、规范化前驱体多重集合与有序操作类型序列组成；同义名归并、化学式标准化和操作归类规则在开发集上确定并冻结。缺少必要字段或无法消歧的记录标为不可判定，不作为负例，并报告排除比例。温度、时间和气氛用于预测特征；条件匹配仅作为字段完整子集上的次要任务，容差和缺失处理规则提前冻结，不把条件不符误判为核心路线从未报道。

每个目标使用相同预算的候选生成规则和随机种子，模型输入可使用目标化学式、候选本身及允许的检索证据，不能读取隐藏参考配方。测试参考论文及其重复记录不进入检索库。候选中没有参考匹配者的目标仍保留并报告，避免通过事后注入正确候选高估性能。用于诊断的参考候选注入实验须单独标记，不混入主指标。

固定 Q 后，库内匹配与未匹配标签均可核验，这解决的是可观测的参考恢复任务。潜在实验成功 Y 与 Z_R 是不同变量。仅观察文献正例时，未知的尝试、报道和收录机制使 P(Y=1 | m,r) 通常不可识别[12]；本课题不通过估计一个类别先验就宣称解决这一问题。

### 3.1.2 约束决策空间与领域评分模型

采用轻量领域 Schema 表达材料、前驱体、工序和条件及其关系。可执行约束包括字段类型、单位换算、非负持续时间以及在反应物、产物和已知开放气体完整时的元素守恒。摄氏温度可为负值，物理温度范围须先转为统一单位。缺少气氛、容器贡献或副产物信息时标记为待核验，不以不完整反应式直接否定路线。

前驱体稳定性、热力学驱动力和凸包能量仅作为经验特征或辅助诊断，不生成文献匹配真值，不把亚稳相记录剔为错误正例。前驱体分解可以参与合

成，因此不设置“前驱体不稳定则路线不可行”的必然规则。约束用于规范候选，不直接决定 Z_R；对抽取记录与规则的冲突进行审计，并报告候选合法率、候选覆盖率及约束导致的参考路线误剔除率。

基线采用结构特征的逻辑回归；领域模型采用可本地运行的类型化决策模型，在训练集内进行必要的轻量适配。检索增强生成（Retrieval-Augmented Generation，RAG）从允许使用的历史语料提供证据，低秩适配（Low-Rank Adaptation，LoRA）作为可选增强。先完成基线和评分导出，再决定是否加入微调；不依赖尚未核实可用的商业接口或自建全文库。

四类校准方案使用同一模型输出的二分类 logit z、同一候选和全部后处理后的评分，任何模型或约束变动都须重新拟合校准器。算力可行性通过固定样本量、序列长度、批大小和设备的预实验报告，不把参数规模换算为未经实测的显存或耗时保证。

### 3.1.3 概率校准策略、缺失实验与预测集构造

主比较包括 S1 未校准、S2 全局校准、S3 独立分组校准和 S4 部分池化校准。分组依据推断时可见的证据元数据，例如允许检索库中的证据条数及训练得到的抽取质量估计；人工审计标签只用于核验，不能作为部署时不可获得的分组特征。分组不直接使用隐藏参考匹配结果，且保留“无检索证据”组。年份只用于划分与偏移分析，不将较新或较旧直接等同于可靠。

S1 使用 sigmoid(z)。S2 拟合 $p=\mathrm{sigmoid}(a\,z+b)$，其中 $a>0$；另设 $b=0$ 的温度缩放对照，以区分截距与分层带来的收益。S3 为每组拟合同形式的 a_g、b_g，使用在开发集冻结的正则化及拟合失败回退规则，单一类别的小组回退到全局参数并报告频率。S4 令 log(a_g) 与 b_g 服从共享总体均值及组间尺度的正态分布，总体均值采用弱信息正态先验，尺度采用半正态先验，预测取后验预测均值[11]。先验尺度在开发集确定；同时比较全局贝叶斯对照，避免将后验平均的收益全部归因于分组收缩。报告收敛诊断、拟合失败及先验敏感性，不预设 S4 最优。

受控标签缺失实验只在原始 Z_R 完整可核验的基准上进行。分别减少模型训练标签量与概率拟合标签量，改变正负标签保留率及分组依赖性，其他环节保持一致。被遮蔽样本不当作负例，所有方法使用相同可见标签；完整测试标签由评估程序保留，不向模型暴露。标签依赖型缺失会改变类别比例，增加采用已知非零保留概率进行逆概率加权的对照，以区分观测偏置与校准模型差

异。某类保留率为零时不使用无定义的权重，也不声称常规监督校准仍可识别。

如开展 PU 扩展，须在完整基准中明确模拟潜在标签及正例标注机制，并分别测试随机正例标注与依赖特征的标注。已知先验只作理想条件对照，估计先验及其敏感性结果分别报告；真实文献数据中无法验证的机制不写成实测事实。受控结论仅适用于所模拟机制，不据此推广为所有材料或所有文献数据库的规律。

预测集在概率拟合完成后另行构造。采用统一的不一致性分数 s(x,y)=1-p_y(x)，从独立保形集的 n 个分数中取 k=ceil((n+1)(1−α)) 阶统计量为阈值；若 k>n，则取正无穷阈值。预测集合为所有满足 s(x,y) 不超过阈值的标签 y。保证对象是校准单位与新单位可交换条件下的边际事件 P(Z_R 属于预测集合)≥1−α[7]，不保证单个样本或每组均达到名义覆盖。

同一目标的候选、同一论文中的不同目标均可能相关。正式覆盖分析以 3.2 定义的关联组为单位，每组先按冻结随机规则抽取一个目标，再从其候选中随机抽取一条，形成互不重叠的保形集与测试集；关联组间可交换是明确假设。全候选覆盖只作描述性指标，不能把路线条数当作独立样本数。总体及各组均报告覆盖率、平均集合大小、空集和双标签集合频率；时序与新化学体系上的结果为偏移压力测试，不承诺同样的分布无关保证。

## 3.2 研究方案

第一阶段，数据与任务审计。优先固定公开固态配方数据的发布版本[1]，完成许可、下载校验、字段和年份可得性检查，保存清洗日志及人工抽查记录。先在固态氧化物子集核实足够的目标组、标签和可见证据分组；若字段或样本不足，缩小条件匹配范围或采用预先定义的粗分组，不以伪造字段填补。数据可得性与标签核验是后续研究的启动条件。

第二阶段，构建参考匹配基准与底座。按论文标识、规范化目标及重复路线关联分组，同组记录不跨数据分区；明确关联组大小及排除规则。建立合法候选生成器、隐藏参考库和历史检索库，完成逻辑回归及类型化模型基线，记录端到端参考恢复率和候选覆盖率。本体粒度、模型选择及检索配置在开发阶段冻结，避免把系统重构同时计入校准收益。

第三阶段，实施四类校准及受控缺失比较。设置训练集 D_train、开发集 D_dev、概率拟合集 D_prob、保形集 D_conf 与测试集 D_test，五者的关联组互不重叠。D_train 拟合底座；D_dev 选择分组、先验、正则化、候选规则与决

策阈值；D_prob 只拟合已选定校准器参数；D_conf 只计算冻结评分的保形阈值，不再调整校准器；D_test 最后一次用于报告。不在同一批样本上拟合概率再计算保形分位数。除受控缺失外，各方案共享相同划分及标签预算。

第四阶段，综合评价与复现。主分析采用关联组随机划分；时序分析使 D_conf 晚于概率拟合期、D_test 晚于 D_conf，其他分区按年份排序，检索证据不得晚于相应预测时间，也不得包含该目标的隐藏参考论文。记录每条检索证据的来源与时间。年份缺失者不进入时序主分析，并报告占比。核查基础模型公开的预训练截止时间；截止时间未知时如实披露，时序划分不能据此证明没有预训练污染。

主指标为目标等权的测试负对数似然与 Brier 分数；期望校准误差使用预先冻结的分箱并作分箱敏感性分析。辅助报告参考恢复率、排序质量、可靠性曲线和最差组表现。各方案在相同测试目标上配对比较，按关联组重采样给出指标差异区间；多方案与多缺失情形的检验预先区分主对照和探索分析，并控制多重比较。不把单次最优值当作稳定结论，也不把均值改善掩盖小组恶化。

决策实验限定为文献核验工作流。设匹配参考事件的收益为 B，执行一次人工核验的成本为 C，简化策略在 pB>C 时接受核验；B、C 为预先给定的模拟参数，另作敏感性分析，测试平均收益由观察到的 Z_R 计算。与固定 Top-k、原始分数阈值及仅在开发集选择的经验阈值策略比较，报告接受率、接受样本错误率及拒答代价。校准无收益或不改变选择时如实报告，不将此收益称为节省真实合成成本。

Raccuglia 等的实验记录[5]仅作为可选的独立成败验证。若其下载、标签及输入字段通过审计，按原任务单独建模和划分，重复校准比较；不与文献匹配标签混合训练，不将该体系表现外推到全部固态材料。合作实验室合成案例取决于实际合作和资源落实，不作为本课题完成的必要前提。

技术路线为：公开数据版本审计 → 分组隔离与参考匹配标注 → 冻结约束候选、检索和底座评分 → 四类概率校准及受控标签缺失 → 独立保形阈值估计 → 参考匹配、预测集效率与模拟核验决策评价。整体流程如图 3-1 所示。

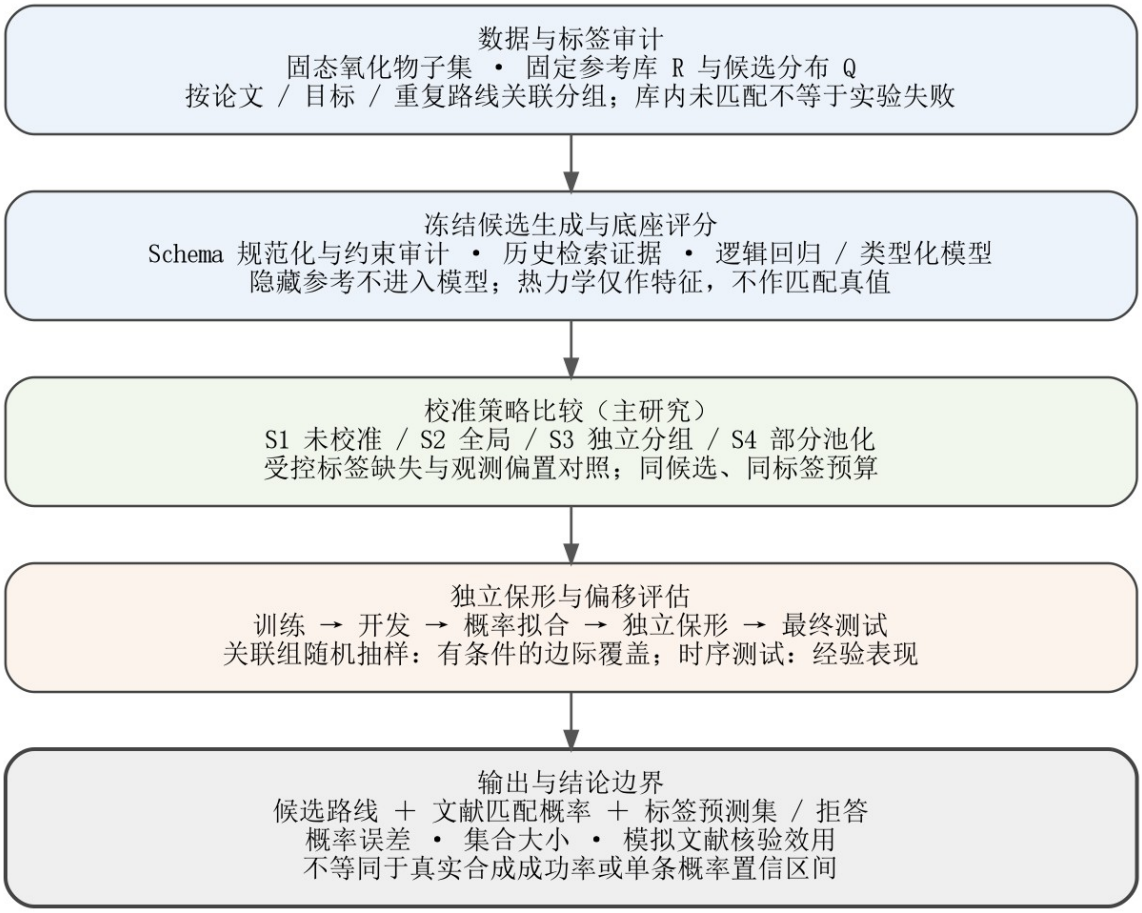



图 3-1　技术路线图

## 3.3 时间安排

本安排为修订后的拟执行计划，不将过去的时间段写成已经完成的研究。阶段是否完成以数据清单、代码、日志及冻结实验记录为准。

2026.10 — 2026.11　完成数据版本、字段与标签审计，明确研究子集、候选规则、分组方式和可执行的划分；完成小规模底座与算力预实验。

2026.12 — 2027.01　完成底座评分导出、全局与分组校准、部分池化实现，冻结先验与拟合回退规则；开展受控缺失预实验并锁定主比较。

2027.02 — 2027.03　完成正式随机分组与时序评价、独立保形分析、分组不确定性及模拟决策评价；整理复现包并撰写论文初稿。

2027.04 — 2027.05　完成结果核验、局限性讨论、论文修改与答辩准备。微调、大规模全文检索及外部成败数据验证均为可选扩展，不挤占主比较的完成时间。

## 4 研究的局限性与预期成果

主任务的标签是固定语料快照中的匹配结果，受数据库覆盖、路线标准化和抽取错误影响。即使匹配概率校准良好，也不能推出真实合成成功率已校准；仅有文献正例时的潜在成功率不可识别性不会因使用 PU 自动消失。

校准效果依赖候选分布与可见证据分组。人工增加不匹配候选会改变基准发生率；部分池化可能过度收缩，极小组参数可能主要由先验决定。本文将报告这些边界，不承诺消除报道偏置、研究者选择偏置或覆盖未知化学空间。

保形保证依赖明确的交换性及独立校准协议。组内相关性、时间变化和化学体系迁移会限制保证的适用范围；经验覆盖达标也不构成假设已被证明的证据。模拟核验效用与合作合成案例均不能代替系统性的真实实验决策验证。

预期成果是一个带版本和标签审计的文献匹配基准、一组可复现的校准策略对照，以及样本量、组间差异和标签缺失机制对结果影响的分析。若复杂模型或部分池化未优于简单方法，将报告负结果与适用边界。以上均为研究计划，不代表已完成实验或已满足学位论文送审要求。

## 参考文献


[1] Kononova O, Huo H, He T, et al. Text-mined dataset of inorganic materials synthesis recipes[J]. Scientific Data, 2019, 6: 203. DOI: 10.1038/s41597-019-0224-1.

[2] Prein T, Pan E, Jehkul J, et al. Language models enable data-augmented synthesis planning for inorganic materials[EB/OL]. arXiv:2506.12557, 2025. DOI: 10.48550/arXiv.2506.12557.

[3] Noh H, Na G S, Lee N, Park C. MSP-LLM: A unified large language model framework for complete material synthesis planning[EB/OL]. arXiv:2602.07543, 2026. DOI: 10.48550/arXiv.2602.07543.

[4] Noh H, Na G S, Pan E, et al. CondMSP: Condition-informed and resource-aware inorganic materials synthesis planning[EB/OL]. arXiv:2610.15603, 2026. DOI: 10.48550/arXiv.2610.15603.

[5] Raccuglia P, Elbert K C, Adler P D F, et al. Machine-learning-assisted materials discovery using failed experiments[J]. Nature, 2016, 533: 73-76. DOI: 10.1038/nature17439.

[6] Guo C, Pleiss G, Sun Y, Weinberger K Q. On calibration of modern neural networks[C]//Proceedings of the 34th International Conference on Machine Learning. PMLR, 2017, 70: 1321-1330. https://proceedings.mlr.press/v70/guo17a.html.

[7] Angelopoulos A N, Bates S. A gentle introduction to conformal prediction and distribution-free uncertainty quantification[EB/OL]. arXiv:2107.07511, 2021. DOI: 10.48550/arXiv.2107.07511.

[8] Geuter J, Cheng A, Alvarez-Melis D. Releasing the inner Jev: A simple recipe for open decision models[EB/OL]. arXiv:2610.17205, 2026. DOI: 10.48550/arXiv.2610.17205.

[9] Nandakishore G. Laya as a typed probabilistic assessor: An independent reproduction and a preregistered study of calibration and selective escalation[EB/OL]. arXiv:2609.33843, 2026. DOI: 10.48550/arXiv.2609.33843.

[10] Kang P, Sun Y, Li Z, et al. CrystalJev: Calibrated foundation-model probabilities decide what to compute next in materials discovery[EB/OL]. arXiv:2610.06985, 2026. DOI: 10.48550/arXiv.2610.06985.

[11] Gelman A, Hill J. Data analysis using regression and multilevel/hierarchical models[M]. Cambridge University Press, 2006. DOI: 10.1017/CBO9780511790942.

[12] Bekker J, Davis J. Learning from positive and unlabeled data: A survey[J]. Machine Learning, 2020. DOI: 10.1007/s10994-020-05877-5. arXiv:1811.04820.