北京科技大学

硕士学位研究生

选题报告及文献综述

论文题目：面向 BCC/B2 高温合金设计的本地小模型偏好对齐与可复现奖励构造

指导教师：艾冬梅

单　　位：数理学院

姓　　名：唐宁俊

学　　号：M202410824

专业名称：统计学

入学时间：2024 年 9 月 5 日

2026 年 10 月（修订）

目　录

1 选题背景及选题意义

1.1 选题背景

1.2 选题意义

2 文献综述

2.1 语言模型用于材料设计

2.2 偏好学习与能力蒸馏

2.3 高熵合金的相形成判据

2.4 本课题与现有工作的边界

3 研究内容、研究方案、时间安排

3.1 研究内容

3.1.1 开源判据与 CALPHAD 计算的一致性对照

3.1.2 带置信度的奖励构造

3.1.3 教学样本选择与本地小模型偏好对齐

3.2 研究方案

3.3 时间安排

4 研究的局限性与预期成果

参考文献

1 选题背景及选题意义

1.1 选题背景

大模型辅助材料设计的能力与它的部署成本之间存在结构性矛盾。 近两年，语言模型在材料设计上的应用从"预测性质"扩展到"生成候选成分"：给定目标性能或设计意图，模型直接输出候选成分配方。这类工作已证明可行——已有研究用三个开源模型（LLaMA-3.1、Gemma-2、OLMo-2）针对 BCC/B2 高温合金这一结构材料类别做偏好微调，使模型生成更可能形成目标相结构的成分[1]。

但这些工作的落地方式存在两个实际障碍。

第一，依赖商业软件的奖励信号使流程不可复现。 上述工作用热力学相计算作为偏好学习的奖励——其逻辑是合理的（用物理判据而非人工标注），但计算依赖商业 CALPHAD 软件及其数据库，数据与模型权重受最终用户许可协议限制，无法随论文发布。结果是：方法可读，流程不可跑。对后续研究者而言，只能"知道可以这么做"，无法"照着做一遍再改进"。

第二，云端大模型的调用成本与数据外发限制了实际使用。 材料研发中的配方数据往往涉及企业内部积累，不便上传至第三方接口；而若长期依赖云服务，调用成本随使用量线性增长，且模型版本由服务商控制，无法锁定。这使"用大模型辅助配方设计"在工业场景中难以常态化。

这两个障碍共同指向同一个技术命题：能否用开源工具构造奖励信号，并用本地小模型完成同等任务？

本课题以 BCC/B2 高温合金为验证场景，研究两个问题：其一，用开源热力学描述符工具构造偏好学习的奖励信号，并量化它与完整 CALPHAD 相计算的一致性边界；其二，让本地部署的小规模语言模型通过偏好对齐获得该任务的能力，并改进教学样本的选择方式以提升有限数据下的学习效率。

1.2 选题意义

其一，使方法从"可读"变为"可跑"。 本课题用两个开源工具替代商业热力学计算：hea-bench（MIT 许可，计算混合熵、混合焓、价电子浓度、原子尺寸失配等标准描述符，并集成经典相预测规则）[2] 与 heacalculator（计算十六个热力学与物理量，集成八种已发表的固溶体形成模型）[3]。二者均通过包管理器分发，无需许可证。同时用 pycalphad（开源 CALPHAD 实现）配合公开

的钢铁热力学数据库做相平衡计算，作为对照基准[4]。这样，整个奖励构造链路可以在任何一台普通机器上复现。

其二，量化"简化判据"的适用边界，而非假定它等价。 用描述符判据替代完整 CALPHAD 计算，必然引入误差。本课题不回避这一点，而是把它作为研究内容：在同一批成分上同时计算描述符判据与 CALPHAD 相平衡结果，统计二者的一致率、分歧模式与分歧集中在哪些成分区域。这一对照的价值在于给出明确的使用边界——后续研究者可以据此判断，在什么情况下可以用轻量判据、什么情况下必须做完整计算。

其三，把奖励的可靠性问题显式化。 描述符判据是对固溶体形成经验的总结，其本身有适用范围。若直接用它做偏好学习的奖励，模型会学到判据的偏差而不自知。本课题的做法是在奖励构造中引入"判据置信度"：当多个描述符模型给出不一致判断、或成分落在训练数据覆盖之外时，降低该样本的奖励权重或将其排除。这使奖励信号带有不确定性标注，而非一刀切。

其四，改进有限教学数据下的学习效率。 若用云端大模型生成教学示范，样本量与调用成本直接挂钩；若用小模型自举，样本质量难以保证。因此"用更少的样本学到更多"有实际价值。本课题研究教学样本的选择策略：在固定样本预算下，优先选取小模型当前容易出错、且能补足尚未覆盖的约束类型的样本，同时惩罚重复。这一改进的动机是朴素的——不是所有示范都值得学——但需要明确的选择规则与公平的对照。

其五，交付可私有化运行的辅助工具。 最终系统在本地运行：模型、判据计算、检索库均不出内网。它的定位是配方方案助手——研究者给出已有的合金成分与修改要求（如降低某元素、保持某相结构），系统给出若干候选及判断依据。本课题不承诺它能发现新材料，只承诺它在明确约束下减少人工检索与方案起草的重复劳动。

2 文献综述

2.1 语言模型用于材料设计

语言模型在材料领域的应用经历了从性质预测到生成设计的迁移。早期工作将材料组成或晶体结构序列化为文本，用预训练模型做分类或回归；后续工作转向生成式：给定目标性质，直接生成候选成分或结构。这类方法的共同假设是——材料的成分-结构-性能关系可以被文本表示承载。

在合金领域，已有面向材料科学继续预训练的语言模型[13]，其提供开源权重与适配代码。进一步地，有工作针对特定结构类别做生成：有研究用偏好学习微调开源语言模型，使其生成更可能形成 BCC/B2 相的超级合金成分。其做法是用直接偏好优化（DPO），奖励信号来自热力学相计算，作者称这是"首次用物理反馈做偏好微调的结构合金设计"。该工作验证了技术路线，但其奖励依赖商业软件，流程不可完全复现。

另有工作提出"语言模型理解需求、修改材料、调用工具评价"的辅助设计范式，把模型定位为设计助手而非全自动发现器[12]。这一范式与本课题的定位一致。

本课题与上述工作的差别有三：奖励用开源判据构造而非商业软件；模型为本地部署的小规模模型；并显式研究教学样本选择对学习效率的影响。

2.2 偏好学习与能力蒸馏

偏好学习使模型在难以定义绝对评分、但可以比较优劣的任务上获得改进。直接偏好优化（DPO）通过成对比较数据直接优化策略，避免了显式奖励模型[5]。其前提是能够构造"更优/更差"的样本对——在材料设计中，这一对可以由物理判据生成（如"形成单相固溶体"优于"析出金属间化合物"）。

能力蒸馏则研究如何把小模型训练到接近大模型的任务水平。早期工作让教师模型生成推理过程作为额外监督[6]；后续研究发现，小模型不应简单模仿大模型的长篇输出，而需要适合自身能力的解题策略[7]。在检索增强场景中，有工作让模型学会"使用相关证据、忽略干扰证据"[8]。

本课题的切入点在教学样本选择：在固定样本预算下，选哪些样本让小模型学得更好。这与"如何生成更好的教师示范"不同，关注的是筛选而非生成。

2.3 高熵合金的相形成判据

高熵合金能否形成单相固溶体，是设计中的核心问题。经典判据基于热力学与几何描述符：混合熵（ΔS_mix）、混合焓（ΔH_mix）、价电子浓度（VEC）、原子尺寸失配（δ）、电负性失配等，配合经验阈值给出判断[16]。这些描述符有闭式表达式，计算成本极低，但准确性有限——不同判据对同一成分可能给出相反结论。

更严格的方法是 CALPHAD 相平衡计算：基于热力学数据库，求解给定温度与成分下的平衡相组成[17]。其准确性依赖于数据库质量，计算成本高于描述符判据但仍远低于第一性原理。

本课题同时使用两者：描述符判据作为主要奖励（成本低，可大规模计算），CALPHAD 计算作为对照基准（用于量化前者的偏差）。这一设计的实质是把"判据的可靠性"当作研究对象，而不是当作已知条件。

2.4 本课题与现有工作的边界

与既有合金生成工作相比：它们用商业热力学软件构造奖励，流程不可复现；本课题用开源工具链，并量化简化判据的误差。

与既有偏好学习工作相比：它们关注方法本身；本课题关注奖励信号的可获得性与可靠性。

与既有智能体式材料设计工作相比：此类工作将贝叶斯优化等工具封装为智能体可调用的能力[14]，其优化对象是搜索策略；本课题的优化对象是语言模型的教学样本，二者不重叠。

与既有高熵合金设计工作相比：本课题不提出新的相形成判据，而是在已有判据中引入置信度加权。

3 研究内容、研究方案、时间安排

3.1 研究内容

本课题以"用开源工具链构造可靠奖励、使本地小模型获得 BCC/B2 高温合金配方生成能力"为目标，研究三个问题。三者有依赖关系：内容一产出奖励信号及其可靠性标注，内容二用该信号训练模型并改进样本选择，内容三集成系统并给出使用边界。

3.1.1 开源判据与 CALPHAD 计算的一致性对照

针对简化判据替代完整计算引入误差的问题，本课题在统一成分集上比较两类判据的输出。

具体做法：构造一个成分集，覆盖 BCC/B2 高温合金的典型元素组合（如 Al-Co-Cr-Fe-Ni-Ti 等体系）与成分范围。对每个成分，同时计算：其一，描述符判据——用 hea-bench 与 heacalculator 计算混合焓、混合熵、VEC、尺寸失配等，套用其集成的多种已发表固溶体形成模型，得到"是否形成单相固溶体"的多模型投票；其二，CALPHAD 判据——用 pycalphad 配合公开的钢铁热力学数据库计算平衡相组成，判定目标温度下是否为单相。比较二者的分类一致率、混淆模式，并分析分歧是否集中在特定元素组合或相边界附近。

成分集的构造参考公开的多主元合金数据集[15]，但不受其覆盖范围限制，而是按目标体系系统地枚举。需明确本部分的局限：公开热力学数据库对多元高熵体系的覆盖有限，pycalphad 在部分成分上可能无法收敛或结果可信度低。因此对照将限定在数据库覆盖良好的子集上，并报告该子集的规模与筛选标准。

评价指标：两类判据的分类一致率与 Cohen's κ；分歧样本在成分空间中的分布；多个描述符模型之间的内部一致性；以及在数据库覆盖不足时的失败率。

3.1.2 带置信度的奖励构造

针对直接用判据做奖励会放大其偏差的问题，本课题在奖励构造中引入可靠性标注。

奖励信号定义为判据输出的加权组合，权重来自三个方面的置信度：其一，多模型一致性——若八个已发表模型中有六个认为形成固溶体，则置信度高；若三对三，则低。其二，成分覆盖度——若成分落在判据的训练数据分布之外，降低权重。其三，与 CALPHAD 判断的一致性——对可计算 CALPHAD 的子集，用其一的一致性校准描述符奖励的可信度。置信度本身也需校准，以免过度自信的权重扭曲偏好对构造[18]。hea-bench 已提供"标记与训练数据不同的合金"这一功能，可直接利用。其三，与 CALPHAD 判断的一致性——对可计算 CALPHAD 的子集，用其一的一致性校准描述符奖励的可信度。

据此把样本分为三类：高置信（作为偏好对的正例）、低置信（排除或降权）、冲突（单独保留分析）。偏好对由高置信正例与低置信负例构成，避免使用同一置信层级内的样本对——因为二者差异可能来自噪声而非真实优劣。

评价指标：不同置信度分层的奖励与 CALPHAD 判据的一致率；置信度与奖励可靠性的相关性；以及剔除低置信样本后训练数据量的损失比例。

3.1.3 教学样本选择与本地小模型偏好对齐

针对有限样本预算下的学习效率问题，本课题研究教学样本的选择策略，并用其训练本地小模型。

模型侧：以 Qwen3 系列为底座（拟选 4B 至 8B 量级，具体规模由预实验确定），用 LoRA/QLoRA 做参数高效微调[9][10]，采用 DPO 做偏好对齐[5]。选

择 Qwen3 的理由是其中文能力与生态支持，且规模档位丰富，便于做规模消融[11]。

样本选择侧（本部分为主算法切入点）：设教学样本池大小为 N，预算为 k（k ≪ N）。提出按"学生薄弱度 + 约束覆盖度 − 重复惩罚"三项加权的选择规则。学生薄弱度由当前模型在样本上的预测熵或判定错误率估计；约束覆盖度按需求类型（如单元素上下界、多元素锁定、总量守恒、相结构保持）分层统计已选样本的覆盖情况；重复惩罚按成分与文本双重相似度计算。该规则在训练过程中迭代更新——每轮训练后重估薄弱度，再选下一批（类似主动学习，但目标是提升对齐效果而非标注效率）。

需设置的对照：随机选择同样预算的样本；仅按学生薄弱度选择；仅按多样性选择；全量训练（作为上界）。四者使用相同底座、相同训练超参、相同预算。

评价指标：生成候选的约束满足率（成分归一、元素上下界、锁定项）；判据判定为形成目标相的比例；与教师大模型（云端）在同一任务上的差距；候选多样性；训练与推理成本。特别地，须诚实报告"小模型是否达到了可用水平"这一判断，若未达到，需分析是数据不足、任务过难还是方法不当。

3.2 研究方案

第一阶段：环境与数据准备。 安装并验证 hea-bench、heacalculator、pycalphad；确认公开热力学数据库的覆盖范围与可用性，明确哪些元素体系可做 CALPHAD 计算；构造成分集与需求模板（含元素上下界、锁定项、目标相结构等约束类型）。本阶段须产出一份可行性记录：三个工具在目标体系上的实际可用性、计算耗时、失败率。

第二阶段：一致性对照。 在同一成分集上计算两类判据，统计一致率与分歧模式，划定可替代与不可替代的边界。本阶段的结果决定第三阶段的奖励构造方式——若一致率过低，则需调整奖励设计或收缩适用范围。

第三阶段：奖励构造与模型训练。 实现带置信度的奖励构造，生成偏好对；用 Qwen3 底座做 LoRA 微调与 DPO 对齐；实现样本选择策略，完成四组对照实验。

第四阶段：系统集成与评测。 集成模型、判据计算与本地检索，形成可运行的配方助手原型；完成端到端评测，测量约束满足率、判据通过率、成本与延迟；给出使用边界说明（哪些情况下判据可信、哪些必须做完整计算）。

评测协议。 按元素体系分组划分训练/验证/测试，避免同体系泄漏；测试集不参与任何超参数或样本选择决策。每个实验重复多次（不同随机种子）并报告均值与离散度。与教师大模型的比较须在相同任务、相同输入信息下进行，明确区分"模型能力差距"与"工具辅助带来的增益"。

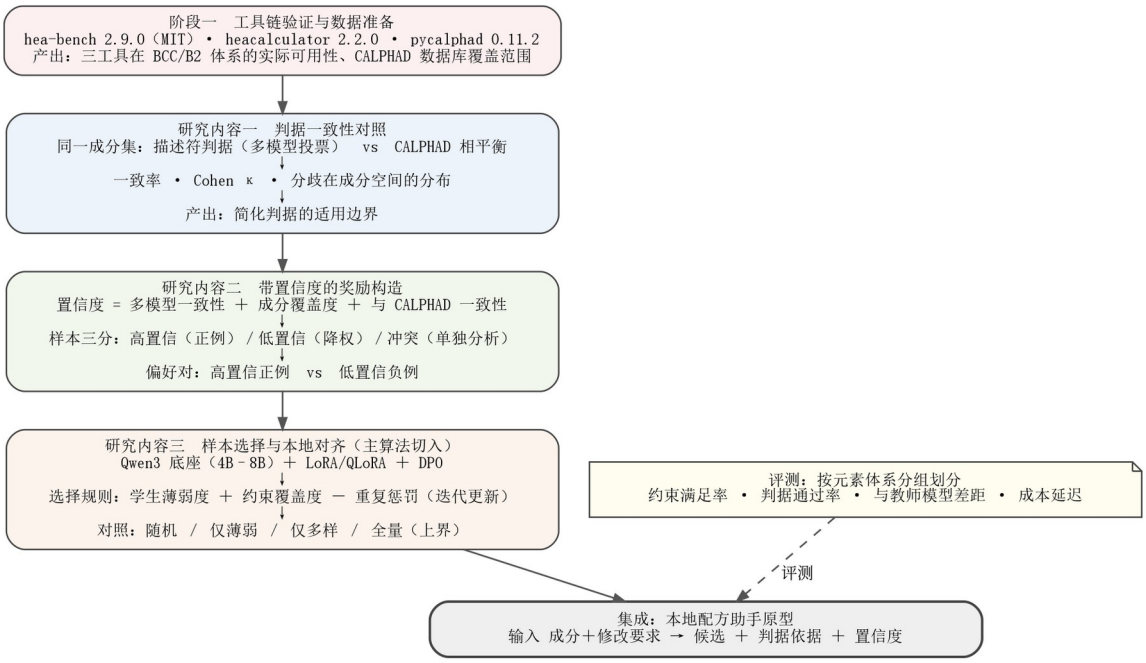


图 3-1　技术路线图

3.3 时间安排

2026.10 — 2026.11　工具链验证与数据准备，确认 CALPHAD 数据库覆盖范围；

2026.12 — 2027.01　描述符判据与 CALPHAD 的一致性对照，划定适用边界；

2027.01 — 2027.02　带置信度的奖励构造与偏好对生成；

2027.02 — 2027.04　教学样本选择策略实现、模型训练与四组对照实验；

2027.04 — 2027.05　系统集成、端到端评测与论文撰写。

4 研究的局限性与预期成果

其一，简化判据与完整计算不等价。 描述符判据是对经验的总结，其准确率低于 CALPHAD 相平衡计算。本课题用一致性对照量化这一差距，但不能消除它。若对照显示一致率过低，则基于描述符的奖励信号可靠性不足，方案的适用性将受限。

其二，公开热力学数据库覆盖有限。 pycalphad 需要热力学数据库文件，公开可得的数据库（如钢铁体系）对多元高熵合金的覆盖不完整。这限制了 CALPHAD 对照的成分范围，也可能使部分体系无法验证。本课题将在第一阶段明确报告覆盖情况。

其三，判据本身不代表可合成性。 热力学上形成固溶体不等于实验上能合成。本课题的奖励信号只反映热力学判据，不包含动力学、工艺可行性等因素。因此模型的输出应被视为"热力学上更有希望的候选"，而非"可合成的材料"。

其四，小模型能力上限未知。 4B 至 8B 量级的模型在配方生成任务上能达到什么水平，尚无公开数据。本课题的目标是"在限定任务上达到可用并有改进"，不承诺接近云端大模型。若实验结果显著低于可用水平，将如实报告并分析瓶颈所在。

其五，样本选择的增益可能有限。 教学样本选择是一个改进点，但其效果依赖样本池的质量与多样性。若样本池本身覆盖不足，选择策略的收益将受限。四组对照实验的设计正是为了检验这一点——若随机选择与所提策略无显著差异，该改进不成立。

其六，本地部署仍有成本。 私有化部署避免了数据外发与按次计费，但仍有硬件采购、模型维护与推理延迟的成本。本课题不宣称本地部署在经济上必然优于云服务，其价值在于数据可控与版本锁定。

预期成果：一份工具链可行性记录（三个开源工具在目标体系上的实际可用性与覆盖范围）；一份描述符判据与 CALPHAD 计算的一致性对照报告，含适用边界；一个带置信度的奖励构造流程；一个经偏好对齐的本地小模型及其与教师模型的对照结果；一个可运行的配方助手原型。若某部分结论为否定（如判据一致性过低、样本选择无增益、小模型未达可用水平），亦作为负结果如实报告并分析原因。

参考文献

[1] Ghosh S, Holgate C, Brodnik N R, Downey D, Daly S. Preference learning from physics-based feedback: tuning language models to design BCC/B2 superalloys[J]. arXiv:2511.12036, 2025.

[2] Fieser D. HEA-Bench: open interpretable descriptors and phase-prediction rules for high-entropy alloys and oxides[J]. Materials, 2026. DOI: 10.3390/ma19143075.

[3] Sarıtürk D, Kalay Y E, Arróyave R. HEACalculator: an open-source Python tool for thermodynamic property calculation and solid solution prediction in high-entropy alloys[J]. arXiv:2606.19661, 2026.

[4] Otis R, Liu Z. pycalphad: CALPHAD tools for designing thermodynamic models, calculating phase diagrams and investigating phase equilibria[CP/OL]. https://pycalphad.org, 2026.

[5] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: your language model is secretly a reward model[C]//Advances in Neural Information Processing Systems, 2023. arXiv:2305.18290.

[6] Hsieh C Y, Li C L, Yeh C K, et al. Distilling step-by-step! Outperforming larger language models with less training data and smaller model sizes[C]//Findings of ACL, 2023. arXiv:2305.02301.

[7] Mitra A, Del Corro L, Mahajan S, et al. Orca 2: teaching small language models how to reason[J]. arXiv:2311.11045, 2023.

[8] Zhang T, Patil S G, Jain N, et al. RAFT: adapting language model to domain specific RAG[J]. arXiv:2403.10131, 2024.

[9] Dettmers T, Pagnoni A, Holtzman A, Zettlemoyer L. QLoRA: efficient finetuning of quantized LLMs[C]//Advances in Neural Information Processing Systems, 2023. arXiv:2305.14314.

[10] Hu E J, Shen Y, Wallis P, et al. LoRA: low-rank adaptation of large language models[C]//International Conference on Learning Representations, 2022. arXiv:2106.09685.

[11] Yang A, Yang B, Zhang B, et al. Qwen2.5 technical report[J]. arXiv:2412.15115, 2024.

[12] Jia S, Zhang Q, Fung V. LLMatDesign: autonomous materials discovery with large language models[J]. arXiv:2406.13163, 2024.

[13] Gangan M S, Das S, Ghosh A, et al. LLaMat: a large language model for materials science[J]. arXiv:2401.00041, 2024.

[14] Li Y, Li S, Deng Y, et al. Agentic-MatriBO: capability-compiled agentic Bayesian optimization for materials and chemical[J]. arXiv, 2026.

[15] Tan R, Li Z, Zhao S, Birbilis N. A primitive machine learning tool for the mechanical property prediction of multiple principal element alloys[J]. arXiv:2308.07649, 2023.

[16] Zhang Y, Zuo T T, Tang Z, et al. Microstructures and properties of high-entropy alloys[J]. Progress in Materials Science, 2014, 61: 1-93. DOI: 10.1016/j.pmatsci.2013.10.001.

[17] Senkov O N, Miller J D, Miracle D B, Woodward C. Accelerated exploration of multi-principal element alloys with solid solution phases[J]. Nature Communications, 2015, 6: 6529. DOI: 10.1038/ncomms7529.

[18] Guo C, Pleiss G, Sun Y, Weinberger K Q. On calibration of modern neural networks[C]//International Conference on Machine Learning. PMLR, 2017: 1321-1330.