北京科技大学

硕士学位研究生

选题报告及文献综述

论文题目：面向材料方向推荐的检索预算分配与无标签决策模型微调研究

指导教师：艾冬梅

单　　位：数理学院

姓　　名：唐宁俊

学　　号：M202410824

专业名称：统计学

入学时间：2024 年 9 月 5 日

2026 年 10 月（修订）

目　录

1 选题背景及选题意义

1.1 选题背景

1.2 选题意义

2 文献综述

2.1 材料方向推荐与文献证据利用

2.2 小模型与决策模型的定位

2.3 弱监督与无标签学习

2.4 本课题与现有工作的边界

3 研究内容、研究方案、时间安排

3.1 研究内容

3.1.1 检索预算的分配策略

3.1.2 文献独立性与弱监督信号构造

3.1.3 决策模型的无标签适配与两级判断架构

3.2 研究方案

3.3 时间安排

4 研究的局限性与预期成果

参考文献

1 选题背景及选题意义

1.1 选题背景

材料研发的周期与成本，长期由"试错"主导。据文献统计，传统试错法研发新材料需十五至二十五年，而现代社会对高性能材料的需求迭代远快于此。为应对这一矛盾，美国于 2011 年提出"材料基因组计划"，欧盟"地平线欧洲"、日本"材料纳米技术计划"以及我国《"十四五"原材料工业发展规划》均将材料数据的智能化利用列为重点方向。其共同逻辑是：以数据与计算替代部分实验，把研发从"做完再测"前移为"先算再选"。

在这一范式转移中，大语言模型被寄予厚望。它能够阅读海量文献、理解自然语言表述的工程需求，并给出方向性建议。然而，将大模型直接用于材料研发面临两个现实障碍。

第一是成本与延迟。 材料方向推荐不是一次性问答，而是需要对大量候选逐条判断。假设一个课题组每月评估一千个候选方向，若每条都由商用大模型判断，按公开基准数据，单次决策约消耗一千四百个输出 token、耗时数秒；累计成本与等待时间都不容忽视。而材料研发的决策往往是探索性的——用户提出一个方向，看到结果后调整，再提出新的方向。这种高频交互使大模型的成本问题被进一步放大。

第二是无标签困境。 训练一个专用的材料判断模型，需要标注数据：哪些方向值得推荐、哪些不值得。但这类标注在实践中极难获得——真正的判断标准是"这个材料能否被做出来、性能是否达标"，而这只能由实验回答，单个实验的成本与周期以周计。文献虽多，但文献报道的是"做过什么"，不是"什么值得做"。缺乏标签，监督学习无从谈起。

这两个障碍共同指向一个被忽视的事实：**材料方向推荐的瓶颈，不在于模型是否足够聪明，而在于证据获取是否高效、监督信号是否可得。**

1.2 选题意义

其一，回应材料研发的真实成本结构。 材料研发的成本分布极不均匀：一次密度泛函计算可能耗时数小时，一次合成实验以周计，而一次文献检索只需秒级。现有系统往往把"检索"当作固定前置步骤——固定检索若干篇，一次性喂给模型，然后判断。这忽视了检索本身是一个可以优化分配的资源：有些问题一篇文献就够，有些需要跨体系交叉验证，有些则根本查不到、应当及早停止。本课题研究如何把有限的计算预算在"检索更多证据"与"直接判断"之间分

配，使单位成本下的判断正确率最大。这一问题的答案对任何依赖文献证据的科学判断任务都适用。

其二，为"无标签"场景提供一条可训练的路径。 材料领域缺乏标注，但并非缺乏信号。同一材料体系往往被多个独立课题组研究，若多篇相互独立的文献对"该体系是否可行"给出一致结论，这一致性本身即构成弱监督信号。本课题研究的思路是：不追求获得真值标签，而是利用独立来源之间的一致性作为训练奖励，使模型学会输出诚实且信息量高的判断。这一思路的价值不止于材料——在医学、化学等同样缺乏标注的科学判断场景中具有普适性。

其三，使小模型承担其应有的位置。 本课题并不主张用小模型替代大模型，而是明确二者的分工：小模型负责高频、低风险的初筛，大模型负责低频、高风险的复核。这一分工的意义在于，它把大模型的成本花在真正需要的地方。若一个课题组每月一千个候选中有八成可由小模型以毫秒级、零成本处理，仅两成需要大模型复核，则总成本可下降一个数量级。这一架构的可行性取决于小模型在微调后能否达到可用的准确率，而这正是本课题要验证的核心问题。

其四，方法的可迁移性。 本课题所研究的两个问题——证据获取的预算分配、无标签条件下的模型适配——都不依赖材料特有的物理知识。前者是信息获取的序贯决策问题，后者是弱监督学习问题。材料文献只是它们的验证场景。因此，本课题的产出不仅服务于材料研发，也为其他"文献密集、标注稀缺"的科学领域提供可复用的方法。

2 文献综述

2.1 材料方向推荐与文献证据利用

材料研发的智能化经历了从计算筛选到生成设计的演进。高通量计算与机器学习模型使候选材料的批量评估成为可能，生成式模型进一步将搜索空间扩展至未被报道的化学空间。然而，候选的丰富并未解决"如何决定优先尝试哪个"的问题。近期研究明确指出，当前 AI 系统能够轻易提出数以百万计的候选，但"决定哪一个值得进入实验"仍是瓶颈。

大语言模型的引入部分缓解了这一问题。基于文本挖掘的合成配方数据使模型可以学习"目标材料—前驱体—工艺条件"的对应关系；检索增强生成（RAG）进一步把外部文献证据引入判断。在材料文献场景中，已有工作构建

了基于图结构的检索增强方案，通过从文献抽取实体并扩展查询来提升召回；也有工作将检索与工具调用结合，形成面向具体任务的智能体流程。

但现有工作普遍把"检索"视为固定的前置动作：给定查询，检索固定数量文档，然后判断。检索多少次、检索什么、何时应当停止，缺少可优化的策略。这一缺失导致两种浪费：对简单问题过度检索，对困难问题检索不足。

2.2 小模型与决策模型的定位

在成本敏感的部署场景中，用小模型处理高频请求、大模型处理困难请求的级联架构已被广泛验证。公开基准数据显示，一个四亿参数级别的本地模型与商用大模型在特定决策任务上可达到相同的准确率，但前者延迟仅为后者的三十分之一，且无调用成本。

在此基础上，一类新的模型范式被提出：决策模型不生成自由文本，而是回答答案空间受约束的问题并输出概率。这一范式的优势有三：其一，输出不可能超出预设选项，从结构上排除格式错误与文本幻觉；其二，一次前向即可给出全部选项的概率，无需自回归生成；其三，概率可经校准，从而支撑阈值型决策。

然而，现有决策模型存在明确的架构限制。以开源实现 Laya 为例，其英文版上下文仅五百一十二个词元，难以容纳多段文献证据；选项共享词元预算，约二十个选项后即出现截断；更关键的是，其在专业判断任务上的零样本准确率仅约百分之三十六，接近三分类随机水平，独立复现研究亦指出其不存在零样本迁移能力。这意味着：**决策模型在通用文本上可用，在专业领域上不可用，除非针对该领域进行微调。**

微调是可行的。同一模型在经领域数据微调后，准确率可提升至约百分之七十七。但微调需要标注数据，而材料领域恰恰缺乏标注。这一矛盾构成了本课题第二个研究问题的起点。

2.3 弱监督与无标签学习

在缺乏真值的条件下获得可用的训练信号，机制设计领域提供了成熟思路。同行预测（Peer Prediction）通过考察多个独立判断者答案之间的互预测性来构造奖励：诚实且信息量高的回答，其与其他独立回答的互预测性高；而敷衍、随机或刻意迎合的回答，互预测性低。该方法的理论保证来自博弈论中的激励相容性，即如实回答是判断者的最优策略。

近期工作将该方法引入大语言模型的评估与后训练，证明其无需真值标签即可有效训练，且具备抗欺骗性；实验显示，即便奖励信号由一个极小的模型提供，仍可恢复大部分性能损失。这为本课题提供了直接的方法基础。

但该方法的成立依赖一个前提：判断者之间相互独立。在材料文献场景中，这一前提需要重新审视——不同文献可能互相引用、可能来自同一课题组、可能基于同一批原始数据。如何定义并估计"文献独立性"，是该思路落地时必须解决的技术问题，也是本课题可能做出贡献的地方。

2.4 本课题与现有工作的边界

与既有材料 RAG 工作相比：现有工作关注检索的召回与增强方式，将检索次数视为固定参数；本课题将检索视为需要分配预算的序贯决策，研究何时检索、检索什么、何时停止。

与既有决策模型工作相比：现有工作提供通用的类型化决策能力，未解决专业领域的适配问题；本课题研究在无标注条件下完成这一适配。

与既有级联架构工作相比：通用级联依据模型置信度决定是否升级；本课题进一步引入证据充分性判断，即"当前证据是否足以支撑判断"，这在文献密集型任务中比模型置信度更可靠。

3 研究内容、研究方案、时间安排

3.1 研究内容

本课题以"在有限预算与无标签条件下，使材料方向推荐的判断更省、更准"为目标，研究检索预算的分配策略与决策模型的无标签适配方法。系统设定为：用户给出材料种类与性能要求，系统自主检索文献证据并给出方向判断；判断分为两级——小模型承担初筛、大模型承担复核。

3.1.1 检索预算的分配策略

针对现有系统固定检索量、忽视证据获取成本差异的问题，本课题研究如何把有限的检索与计算预算分配到最需要的地方。

将检索过程形式化为序贯决策：状态为已获取的证据集合与剩余预算，动作为"继续检索某一类证据"或"基于当前证据作出判断"或"终止并声明证据不足"，目标为在总预算约束下最大化判断正确率。由于不同类型动作的成本差异

可达数个数量级——一次文献检索与一次大模型推理、一次结构计算分属不同量级——该分配问题不同于已有的同质算力分配问题。

方法上拟以信息增益衡量一次检索的价值，并检验其作为集合函数的次模性。若次模性成立，则贪心策略可给出近似最优保证；若不成立，则需给出替代的界或启发式。研究内容包括：信息增益的估计方法、次模性的实证检验、贪心策略与均匀检索策略的成本—准确率对比。

验证指标为：同等预算下的判断正确率、单位正确判断的预算消耗、平均检索轮次、证据冗余率。对照方法为固定检索量策略与基于模型置信度的启发式策略。

3.1.2 文献独立性与弱监督信号构造

针对材料领域缺乏标注的问题，本课题研究如何从文献之间的一致性中构造训练信号。

核心假设是：同一材料体系若被多个相互独立的来源一致报道，则其结论的可信度高；若来源高度相关，则一致性不构成独立证据。因此首要技术问题是独立性度量。拟从三个角度刻画：引用关系（是否互相引用）、来源结构（是否同一课题组、同一期刊流派）、内容重叠（表述是否雷同）。据此构造加权的独立源计数，作为一致性信号的置信权重。

在此基础上构造弱监督奖励：对同一体系的多条证据，若独立来源一致地支持某判断，则给予高奖励；若独立来源相互矛盾，则降权或排除；若仅单一来源，则不作为训练样本。需重点处理两类困难：其一，多数体系可能只被单一文献报道，可用样本量可能不足，须先做数据审计；其二，来源表述差异可能被误判为矛盾，需设计容错的一致性判定。

该部分的核心贡献在于：将同行预测的"独立判断者"替换为"独立文献来源"，并给出文献独立性在材料场景下的可操作定义与估计算法。

3.1.3 决策模型的无标签适配与两级判断架构

针对决策模型在专业领域零样本失效的问题，本课题研究如何利用上述弱监督信号完成模型适配，并将其嵌入两级判断架构。

模型侧：选择一个上下文与选项预算不构成硬约束的小模型作为底座（候选包括基于 LoRA 适配器架构的开源决策模型，其上下文与选项容量均优于现有编码器式实现），以弱监督奖励进行微调。训练目标不仅追求判断准确，还要求概率校准——因为两级架构依赖置信度阈值决定是否升级至大模型。

架构侧：小模型对每个候选给出判断及置信度；置信度高于阈值者直接采纳，低于阈值者升级至大模型复核。阈值由验证集确定，并对其代价敏感性作分析。需与三个基线对比：全部由大模型判断、全部由小模型判断、按模型原始置信度决定的朴素级联。

验证指标为：微调后判断准确率与校准误差、升级率、端到端成本与延迟、以及"单位成本下的正确判断数"。特别地，须诚实报告若微调后准确率未达可用水平时的结论。

3.2 研究方案

第一阶段：基础审计与可行性验证。 本阶段的目的是确认三个前提是否成立，若任一不成立则调整方案而非强行推进。其一，文献库的检索质量：抽样若干查询，人工判定检索结果相关性，给出命中率基线。其二，可训练样本量：统计文献库中同一体系被多篇独立来源报道的比例，该比例决定弱监督方法的可用性。其三，底座模型的领域适配潜力：用少量样本做微调试点，观察准确率是否显著脱离随机水平。三项审计的结果将写入论文，作为方法设计的事实依据。

第二阶段：检索预算分配策略。 构造检索—判断的序贯决策环境，实现信息增益估计与贪心分配策略，检验次模性。与固定检索量、置信度启发式两类基线对比，绘制成本—准确率曲线。

第三阶段：弱监督信号构造与模型微调。 实现文献独立性度量与一致性加权，构造训练样本，完成模型微调与校准。与"仅用单一来源样本"、"不加权一致性"两个消融对比，以说明独立性度量的作用。

第四阶段：两级架构集成与评测。 集成为完整系统，测量端到端成本、延迟与判断质量，确定最优升级阈值，完成消融与敏感性分析。评测须在固定的数据划分上进行，检索库的时间边界须冻结，测试集不得参与任何超参数选择。

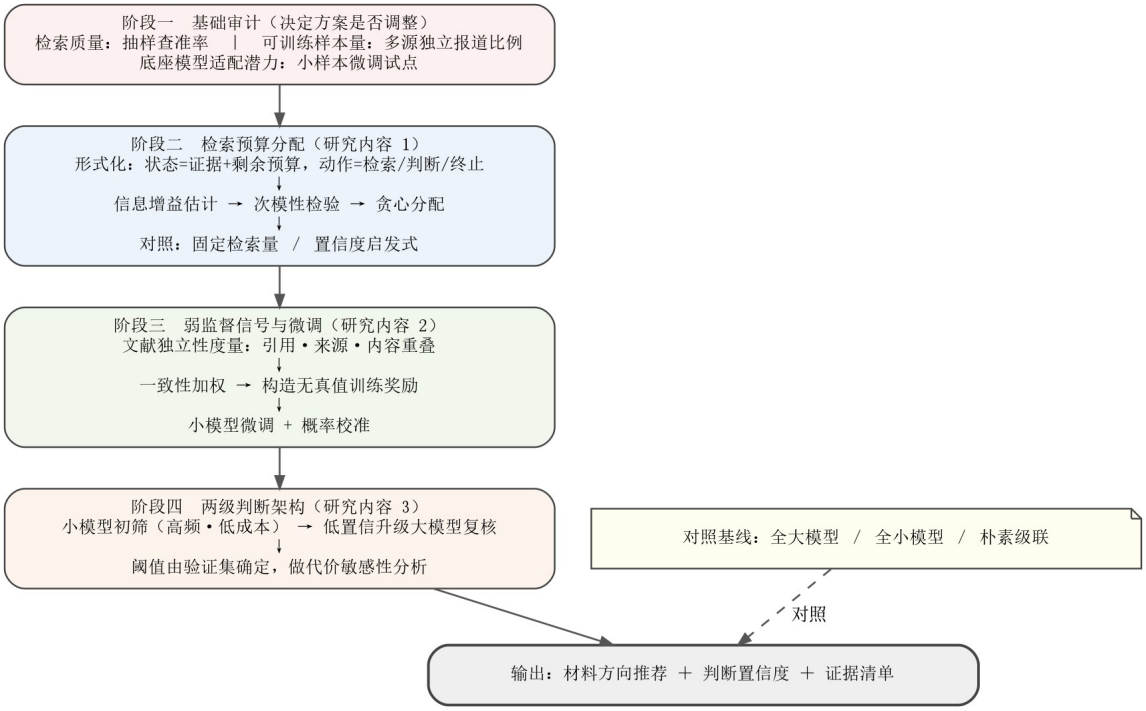


图 3-1　技术路线图

3.3 时间安排

2026.10 — 2026.11　三项基础审计（检索质量、可训练样本量、微调试点），确定方案是否调整；

2026.12 — 2027.01　检索预算分配策略实现与实验，完成次模性检验与基线对比；

2027.02 — 2027.03　文献独立性度量与弱监督信号构造，完成模型微调与校准；

2027.04　两级架构集成、端到端评测与消融分析；

2027.05　结果整理、系统文档与论文撰写。

4 研究的局限性与预期成果

其一，检索质量是全局前提。 本课题所有方法都建立在"文献检索能够返回相关信息"这一前提上。若文献库的检索质量不足，信息增益曲线将趋于平坦，预算分配的意义随之消失。第一阶段审计将量化这一风险，但审计本身不能改善检索质量。

其二，独立性的估计是近似的。 引用关系、来源结构与内容重叠只能部分刻画独立性。同一课题组的不同论文可能不相互引用却同源；不同课题组的论

文可能因使用相同模板而内容雷同。独立性度量的误差会传导至弱监督信号的可靠性，进而影响微调效果。本课题将以消融实验量化这一影响，但无法完全消除。

其三，样本量可能不足。 若文献库中多数材料体系仅有单一来源报道，可供弱监督训练的样本将大幅减少。该风险将在第一阶段审计中暴露；若确认不足，方案将退回为"仅用小模型做零样本初筛"，其价值相应降低。

其四，结论限于文献层面。 本课题的判断对象是"该方向是否得到文献证据支持"，而非"该方向的材料能否被实验做出"。二者不可互换：文献未报道既可能因为不可行，也可能因为无人尝试。系统输出的概率不应被解读为实验成功率。

其五，成本收益为离线估算。 端到端的成本与延迟在同构环境下测量，真实部署中受网络、并发与接口价格波动影响，实际收益可能偏离估算。

预期成果：一个可运行的文献证据驱动的材料方向推荐原型系统，包含检索预算分配器、弱监督训练的决策模型与两级判断架构；一组在固定协议下与基线方法的成本—准确率对照结果；以及三项关于检索质量、样本可得性与模型适配潜力的实证审计结论。若某部分结论为否定（例如预算分配未优于固定策略、或微调后准确率不足），亦作为负结果如实报告并分析原因——对后续研究者而言，明确"此路不通"同样具有价值。

参考文献

[1] Wang Y, Wu Z, Lu J, et al. Beyond structure: revolutionising materials discovery via AI-driven synthesis protocol-property relationships[J]. Journal of Physics: Materials, 2026. DOI: 10.1088/2515-7639/ae6e72.

[2] Gyawali P, Bautista-Hernández A, Romero A H. Acceleration, agency, and foundations: ten influential arXiv directions in AI for materials science[J]. Journal of Physics: Materials, 2026. DOI: 10.1088/2515-7639/ae512f.

[3] Kononova O, Huo H, He T, et al. Text-mined dataset of inorganic materials synthesis recipes[J]. Scientific Data, 2019, 6: 203. DOI: 10.1038/s41597-019-0224-1.

[4] Zeni C, Pinsler R, Zügner D, et al. A generative model for inorganic materials design[J]. Nature, 2025, 639: 624-632. DOI: 10.1038/s41586-025-08628-5.

[5] Kim S, Choi J, Jang K, et al. Materealize: a multi-agent deliberation system for end-to-end material design and synthesis[J]. arXiv:2601.15743, 2026.

[6] Noh H, Na G S, Pan E, et al. CondMSP: condition-informed and resource-aware inorganic materials synthesis planning[J]. arXiv:2610.15603, 2026.

[7] Kang P, Sun Y, Li Z, et al. CrystalJev: calibrated foundation-model probabilities decide what to compute next in materials discovery[J]. arXiv:2610.06985, 2026.

[8] Geuter J, Cheng A, Alvarez-Melis D. Releasing the inner Jev: a simple recipe for open decision models[J]. arXiv:2610.17205, 2026.

[9] Laya as a typed probabilistic assessor: an independent reproduction and a preregistered study of calibration and selective escalation[J]. arXiv:2609.33843, 2026.

[10] Qiu et al. Truthfulness despite weak supervision: evaluating and training LLMs using peer prediction[C]//International Conference on Learning Representations, 2026. arXiv:2601.20299.

[11] Chen L, Zaharia M, Zou J. FrugalGPT: how to use large language models while reducing cost and improving performance[J]. arXiv:2305.05176, 2023.

[12] Alvi S M A A, Janssen J, Perez D, et al. Surrogate-gated generation and foundation-model embeddings for Bayesian materials design[J]. arXiv:2606.28578, 2026.

[13] Guo C, Pleiss G, Sun Y, et al. On calibration of modern neural networks[C]//International Conference on Machine Learning. PMLR, 2017: 1321-1330.

[14] Angelopoulos A N, Bates S. A gentle introduction to conformal prediction and distribution-free uncertainty quantification[J]. arXiv:2107.07511, 2021.

[15] Raccuglia P, Elbert K C, Adler P D F, et al. Machine-learning-assisted materials discovery using failed experiments[J]. Nature, 2016, 533: 73-76. DOI: 10.1038/nature17439.

[16] LeMaterial. LeMat-GenBench: a unified evaluation framework for crystal generative models[J]. arXiv:2512.04562, 2025.

[17] Prein T, Pan E, Jehkul J, et al. Language models enable data-augmented synthesis planning for inorganic materials[J]. arXiv:2506.12557, 2025.

[18] Borg C K H, et al. Quantifying the performance of machine learning models in materials science: a case study in multi-principal element alloys[J]. arXiv:2308.07649, 2023.