北京科技大学

硕士学位研究生

选题报告及文献综述

论文题目：面向稀疏文献数据的合金性能预测：覆盖度建模、相结构分层与成对约束

指导教师：　　艾冬梅

单　　位：　　数理学院

姓　　名：　　唐宁俊

学　　号：　　M202410824

专业名称：　　统计学

入学时间：　　2024 年 9 月 5 日

2026 年 10 月（修订）

目　录

1 选题背景及选题意义

1.1 选题背景

1.2 选题意义

2 文献综述

2.1 材料性能预测与数据困境

2.2 正例—无标签学习

2.3 分层建模与成对学习

2.4 本课题与现有工作的边界

3 研究内容、研究方案、时间安排

3.1 研究内容

3.1.1 文献覆盖度的概率建模

3.1.2 相结构条件化的分层性能预测

3.1.3 同文献内的成对排序约束

3.2 研究方案

3.3 时间安排

4 研究的局限性与预期成果

参考文献

1 选题背景及选题意义

1.1 选题背景

材料研发的周期与成本长期由"试错"主导。为应对这一矛盾，美国于 2011 年提出"材料基因组计划"，欧盟"地平线欧洲"、日本"材料纳米技术计划"以及我国《"十四五"原材料工业发展规划》均将材料数据的智能化利用列为重点方向。其共同逻辑是：以数据与计算替代部分实验，把研发从"做完再测"前移为"先算再选"。

在这一范式下，机器学习辅助合金设计已有大量工作。然而，这些模型的实际效能受制于一个常被提及但少有量化的问题：**文献数据本身的稀疏与噪声**。本课题以公开的多主元合金数据集为对象，先做数据审计，再依据审计结果设计方法。四个实测结论构成本课题的问题定义。

第一，文献覆盖极度稀疏。 该数据集含 1,545 条记录、630 个唯一成分、265 篇文献、208 个元素组合。**630 个成分中有 556 个（88.3%）仅由单一文献报道**；有两个及以上来源的仅 74 个（11.7%），三个及以上的仅 35 个（5.6%）。这意味着"多来源交叉验证"在该数据上基本不可行。

第二，同一成分的重复测量存在巨大离散。 数据中存在 1,380 对成分完全相同（原子比差异为零）、工艺相同的记录对，其屈服强度差异的**中位数为 312.8 MPa**。同一成分测两次相差三百余兆帕，说明文献数据的工艺细节与测试条件差异远大于成分本身的影响。这一噪声水平为任何成分—性能建模设定了上限。

第三，成分变化与性能变化之间不存在可用的平滑关系。 在同文献、同工艺、同相结构、同元素集合的 1,228 对成分对中，成分距离与性能差异的相关系数仅为 0.0148（置换检验 $p = 0.296$），**不显著**。具体反例：成分距离 0.008（约 2% 的碳含量差异）的对，屈服强度从 243 变化到 446 MPa。这说明依赖"成分梯度连续性"的自监督方案在此数据上不成立。

第四，相结构是显著的分层变量。 在严格同文献、同工艺、同测试温度的成分对中（同相 858 对、异相 298 对），同相与异相的屈服强度差异分布存在显著差异（**Mann-Whitney U 检验，$p < 0.0001$**）。但差异幅度随成分距离区间变化，不宜简化为固定倍数。

上述四点共同说明：**该数据集的困难不在于样本总量，而在于单来源、高噪声、非平滑。** 直接套用常规监督学习或生成模型，会在这三个特性上同时失配。本课题据此设计方法。

1.2 选题意义

其一，把"数据稀疏"从抱怨转化为可建模的对象。 现有材料机器学习工作多以"数据少"作为动机一笔带过，随后仍按常规监督学习处理。本课题的做法不同：既然 88.3% 的成分只有单一来源，"有没有文献报道"本身就是一个可学习的事件。这一事件与"材料是否值得研究"高度相关——被报道过的成分，是有人做过的成分；未被报道的，可能是没人做，也可能是做了没成功。**这一结构性缺失恰是正例—无标签（Positive-Unlabeled，PU）学习的标准设定**。把任务重构为 PU 问题后，稀缺的"正例"不再是缺陷，而是设定本身。

其二，量化数据噪声的上限，避免方法设计的盲目性。 312.8 MPa 的重复测量离散意味着：即便模型完美学到成分—性能映射，其可达到的精度也存在无法突破的天花板。明确这一天花板的意义在于——它使"提升准确率"这一目标变得可校准：任何方法若声称显著超越该噪声水平所允许的精度，都应被质疑。本课题将在论文中给出该噪声水平对可达到的 R^2 上界的估计。

其三，为"异质数据应当分层"提供可检验的依据。 相结构（BCC/FCC/其他）对性能的影响不是新知识，但在数据驱动建模中常被忽略。本课题以 1,156 对严格可比的成分对证明同相与异相的差异分布显著不同（$p < 0.0001$），从而说明：**把不同相的数据混在一起训练，等于在假设一个不成立的同分布前提**。分层的价值不在于新奇，而在于它修正了一个普遍被默认但错误的假设。

其四，成对约束为高噪声数据提供比绝对回归更稳的学习信号。 在 312.8 MPa 的噪声下，预测绝对性能值几乎不可行；但同一文献中同批样品的**相对高低**通常可靠。本课题用成对排序替代绝对回归，把学习目标从"预测数值"改为"预测次序"，这与数据的可信度结构相匹配。

其五，方法的可迁移性。 上述三个技术点——稀疏正例下的覆盖度建模、异质分组下的分层估计、高噪声下的成对约束——均不依赖合金特有的物理知识。它们适用于任何"文献密集、标注稀缺、测量噪声大"的领域。合金数据只是验证场景。

2 文献综述

2.1 材料性能预测与数据困境

机器学习在合金性能预测上已有系统工作。早期研究以成分与工艺描述符为输入，用随机森林、支持向量回归等方法预测屈服强度、硬度等指标；后续工作引入图神经网络与成分图表示，提升了对复杂成分空间的表达能力。多主元合金因其成分空间巨大而成为测试这些方法的典型场景，已有工作构建了公开数据集并给出基线模型[3]。

但这些工作的作者普遍承认数据的局限。有研究明确指出其模型"是一个初步工具，未纳入多主元合金的生产与加工路线等因素"，即工艺与相结构信息未被建模[3]。另有工作指出材料数据集的冗余与重复是影响机器学习结果的实质问题，并专门提出冗余控制方法[4]；材料数据库的聚合工作亦须专门设计去重流程[5]。

近期研究进一步量化了文献数据的质量问题。对文本挖掘合成配方数据的分析显示，不同来源对同一材料的记录存在系统性差异。本课题的审计结果与这一判断一致：同一成分的重复测量中位差异达 312.8 MPa。

2.2 正例—无标签学习

当数据中只有正例与未标注样本、而缺乏明确负例时，标准监督学习会产生系统偏差。正例—无标签学习（PU Learning）为此提供了成熟框架：将未标注集视为正例与负例的混合，通过估计类别先验或调整损失函数，得到对真实后验的估计[6][7]。代表性方法包括 Elkan-Noto 的两步法（先训练分类器区分正例与未标注，再按先验校正）与非负 PU 学习（直接优化无偏风险估计）。

在材料领域，PU 学习已被用于"可合成性预测"——即判断某化合物能否被合成。这类工作的动机与本课题相同：合成失败的实验往往不被发表，因而缺乏负例。已有工作结合计算与文献数据，用 PU 学习预测钙钛矿的可合成性[8]；也有工作提出双分类器 PU 框架以提升可合成性预测的稳定性[9]。

本课题与这些工作的区别在于目标不同。 它们预测的是二元的"能否合成"，本课题建模的是"**文献覆盖度**"——即给定成分被文献报道的概率，这是一个连续的概率估计，且其用途是作为推荐排序的特征与不确定性来源，而非直接的可行性判断。

2.3 分层建模与成对学习

当数据存在明确的异质分组时，忽略分组会导致拟合偏差。分层建模通过为各组设定共享先验或独立参数来处理这一问题：完全独立的拟合在小组上方差过大，完全合并则抹平组间差异，部分池化在二者之间取折中[10]。

在材料领域，相结构是天然的分层变量。不同晶体结构的变形机制不同，其强度—成分关系的形态亦不同。但现有数据驱动模型多将相结构作为普通特征而非分层条件，这意味着模型被迫用一个统一的函数拟合不同的物理机制[3]。

成对学习（pairwise learning / learning to rank）在信息检索领域已成熟，其核心是把"预测数值"改为"预测相对次序"[11]。在测量噪声大而相对次序可靠的场景中，成对目标比绝对回归更稳健。材料领域已有工作用排序方法处理性能优化，但将其用于"压制文献测量噪声"的思路尚未见报道。

2.4 本课题与现有工作的边界

与既有材料性能预测工作相比：它们通常在完整数据集上做监督回归，把数据稀疏与噪声当作既定条件接受[3]；本课题先量化噪声上限，再据此选择匹配的学习目标。

与既有 PU 应用相比：已有的材料 PU 工作服务于"可合成性"这一二元判断[8][9]；本课题用它建模文献覆盖度，作为推荐系统的一个概率特征。

与既有分层建模相比：现有工作把相结构当作特征[3]；本课题把它当作分层条件，并输出条件方差。

与既有排序学习相比：本课题的排序目标不是提升推荐质量，而是**对抗测量噪声**——这是由 312.8 MPa 的实测数字直接推出的设计选择。

3 研究内容、研究方案、时间安排

3.1 研究内容

本课题以"在稀疏、高噪声的文献数据上做出可用的合金性能预测与方向推荐"为目标，基于前述四项数据审计结论，依次研究三个问题。三者有明确的依赖关系：覆盖度建模回答"哪些成分值得关注"，分层估计回答"性能如何预测"，成对约束回答"在高噪声下如何让预测更稳"。

3.1.1 文献覆盖度的概率建模

针对 88.3% 的成分仅由单一文献报道这一事实，本课题将"成分是否被文献报道"建模为可学习事件，用 PU 学习框架估计其概率。

形式化如下：设成分 x 与二元事件 $y \in \{0,1\}$ 表示是否存在文献报道。实际观测到的是正例集 P（训练数据中的 630 个成分）与未标注集 U（候选成分空间）。设 $s \in \{0,1\}$ 表示样本是否被选入正例集，则通过训练分类器区分 P 与 U 可得到 $g(x) = P(s=1 \mid x)$，再按 $P(y=1 \mid x) = g(x)/c$ 校正，其中 $c = P(s=1 \mid y=1)$ 可从验证集估计。

本研究内容的关键技术点有三。其一，**未标注集 U 的构造**：候选空间的界定直接决定问题的难度与结果的可解释性，需明确采用元素组合枚举还是成分扰动生成，并说明依据。其二，**类别先验 c 的估计**：该参数不可直接观测，拟用交叉验证与敏感性分析给出其合理范围而非单一估计值。其三，**覆盖度的含义界定**：模型学到的"被报道概率"混合了"材料可行性"与"研究热度"两个因素，二者无法从现有数据分离，必须在论文中明确说明，不得将其解释为可行性。

评价指标为：在留出的已知成分上区分"被报道"与"未报道"的 AUC 与 PR-AUC；在 208 个元素组合上做留一体系交叉验证以检验泛化；概率校准误差（ECE）[19]。对照方法为直接用频次统计的基线、以及不含 PU 校正的普通分类器。

3.1.2 相结构条件化的分层性能预测

针对混相数据同分布假设不成立的问题（Mann-Whitney $p < 0.0001$），本课题将相结构作为显式分层条件，并输出条件不确定性。

模型形式为全概率分解：$P(\text{YS} \mid x) = \sum_{\phi} P(\phi \mid x) \cdot P(\text{YS} \mid x, \phi)$，其中 ϕ 为相结构（BCC、FCC、其他）。第一步从成分预测相，是分类任务；第二步在各相内预测性能，是回归任务。相概率模糊时，混合分布的方差自然增大，从而使预测区间变宽——这一机制使"相不确定"与"性能不确定"在同一个模型中联通。

本研究内容的关键问题是**"其他"相的处理**。数据审计显示，在严格可比的成分对中，"其他"相占同相对的一半左右。将"其他"视为单一相在物理上不合理，因其混杂了多种结构类型。拟比较两种处理：其一，将"其他"作为独立相

参与建模；其二，将其作为无标签样本，用半监督方式处理。二者的对比本身构成对该数据质量问题的量化。

评价指标为：分层与不分层的 MAE/RMSE 对比；预测区间覆盖率（PICP）与区间宽度[20]；相预测准确率；以及在高噪声背景下的 R^2 上界估计（基于 312.8 MPa 噪声水平推导）。对照为不分层的单一回归模型与其同等容量下的表现。

3.1.3 同文献内的成对排序约束

针对 312.8 MPa 的测量噪声使绝对回归难以奏效的问题，本课题引入成对排序目标，用同文献内的相对次序替代绝对数值作为监督信号。

其合理性在于：同一文献报道的同批样品通常采用相同工艺与测试设备，其**相对高低**比绝对值可靠。设同一文献、同一相内的两个成分对 (i,j)，其真实性能排序为 $y_i > y_j$，则用合页损失约束预测排序：$L_{\text{pair}} = \sum \max(0, -(\hat{y}_i - \hat{y}_j) \cdot \text{sign}(y_i - y_j) + m)$，其中 m 为间隔。该目标与回归损失联合优化。

本研究内容须处理两个问题。其一，**同文献内样本对的可比性**：即使同文献同工艺，不同测试温度或不同试样尺寸的数据也不可直接比较，需按字段过滤并报告剩余对数。其二，**真实噪声对排序的污染**：若两个成分性能差小于测量噪声，则其"真实排序"不可靠，应设阈值过滤或降权，阈值由噪声水平确定。

评价指标为：成对准确率；Kendall τ 与 NDCG@k[11]；以及在留出体系上的排序稳定性。对照为纯回归损失、以及含与不含噪声阈值的两版成对损失。

3.2 研究方案

第一阶段：数据审计与基线（已完成初步工作）。 已完成的工作包括：数据集下载与校验（Apache-2.0 许可，sha256 校验）、字段定义、单来源比例统计（556/630 = 88.3%）、重复测量离散度（1,380 对，中位 312.8 MPa）、成分梯度连续性检验（r = 0.0148, p = 0.296）、相结构分布差异检验（Mann-Whitney $p < 0.0001$）。第一阶段剩余工作为：构造 PU 学习的候选空间 U，并完成噪声水平对 R^2 上界的推导。

第二阶段：覆盖度建模。 实现 Elkan-Noto 与非负 PU 两种方案，估计类别先验并做敏感性分析，完成留一体系交叉验证。与频次基线、普通分类器对比。

第三阶段：分层性能预测。 实现相预测与相内回归的两级模型，比较"其他"相的两种处理方式，输出条件方差并检验区间覆盖率。与不分层基线对比。

第四阶段：成对约束与集成。 实现成对排序损失与噪声阈值过滤，与回归目标联合训练。将三个模块集成为推荐原型：输入成分与性能要求，输出候选排序、覆盖度提示与预测区间。在留出体系上完成最终评测。

评测协议。 所有评测采用按元素组合分组的划分，避免同体系样本泄漏至测试集；含年份信息时另做时序验证。超参数在选择集上确定后冻结，测试集仅用于最终报告。每个实验重复多次并报告均值与离散度，鉴于数据噪声较大，须报告置信区间而非单点数值。

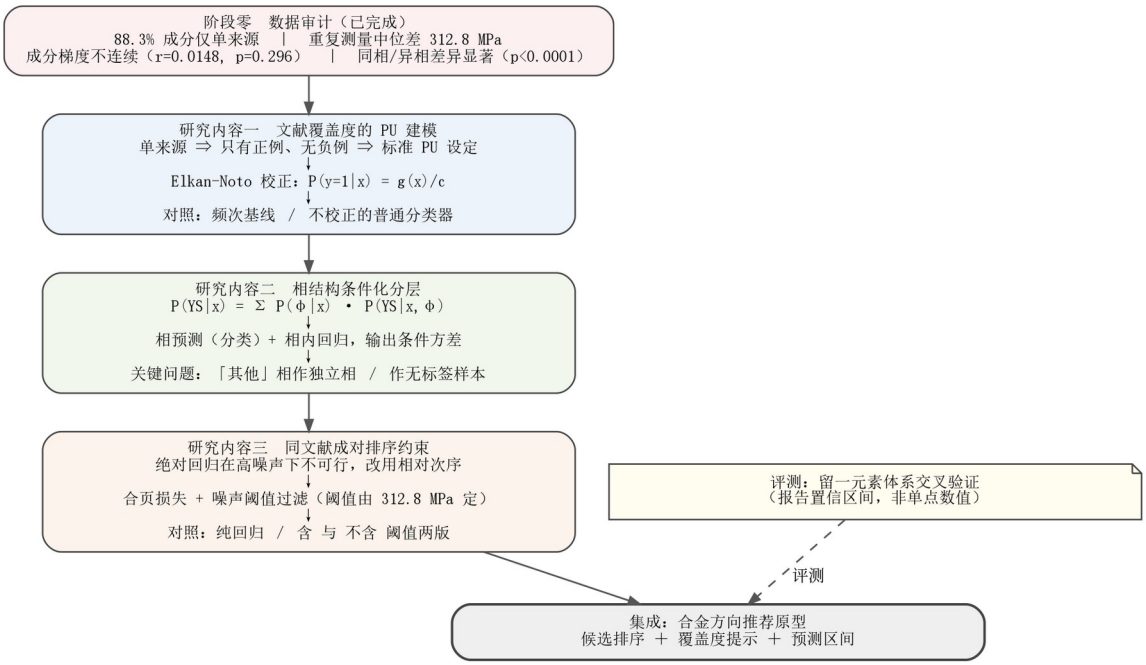


图 3-1　技术路线图

3.3 时间安排

2026.10 — 2026.11　完成候选空间构造与噪声上界推导，实现覆盖度建模基线；

2026.12 — 2027.01　覆盖度建模的完整实验与留一体系验证；

2027.02 — 2027.03　相结构分层模型实现与"其他"相处理方式对比；

2027.03 — 2027.04　成对约束实现、三模块集成与推荐原型；

2027.04 — 2027.05　最终评测、结果整理与论文撰写。

4 研究的局限性与预期成果

其一，覆盖度的含义不可分离。 模型估计的"文献报道概率"混合了材料可行性与研究热度两个因素。热门体系被大量报道，不是因为更容易合成，而是因为更多人去研究。现有数据无法分离这两个因素，因此该概率只能作为推荐的辅助特征，不可作为可行性判断。

其二，噪声上限可能使某些目标不可达。 312.8 MPa 的重复测量离散意味着纯数据驱动的绝对性能预测精度存在硬上限。本课题将明确报告这一上限，并对超过该上限的精度提升持怀疑态度。

其三，相结构的标注质量有限。 数据中"其他"相占相当比例且内部异质。将其视为单一相是权宜之计，将其作为无标签样本则依赖半监督方法的有效性。两种处理都不完美，本课题将如实报告各自的代价。

其四，成对约束的效果依赖排名可靠性。 若真实性能差异小于测量噪声，则监督信号本身错误。噪声阈值只能过滤明显不可靠的对，无法保证剩余对全部可靠。

其五，结论限于该数据集与文献层面。 本课题的所有实验基于公开的多主元合金数据集，其覆盖的体系与工艺有限。结论不宜外推至其他材料类别；且判断对象是文献层面的事件，不等价于实验事实。

预期成果：一份关于该数据集的完整审计报告（含四项实测结论）；覆盖度建模、分层预测与成对约束三个模块的实现与对照结果；一个可运行的合金方向推荐原型。若某模块未达预期（如 PU 覆盖度无法有效泛化、分层未优于不分层），亦作为负结果如实报告并分析原因——鉴于本课题的多个设计决策均由数据审计直接推出，负结果同样具有诊断价值。

参考文献

[1] Wang Y, Wu Z, Lu J, et al. Beyond structure: revolutionising materials discovery via AI-driven synthesis protocol-property relationships[J]. Journal of Physics: Materials, 2026. DOI: 10.1088/2515-7639/ae6e72.

[2] Gyawali P, Bautista-Hernández A, Romero A H. Acceleration, agency, and foundations: ten influential arXiv directions in AI for materials science[J]. Journal of Physics: Materials, 2026. DOI: 10.1088/2515-7639/ae512f.

[3] Tan R, Li Z, Zhao S, Birbilis N. A primitive machine learning tool for the mechanical property prediction of multiple principal element alloys[J]. arXiv:2308.07649, 2023.

[4] MD-HIT: machine learning for material property prediction with dataset redundancy control[J]. arXiv, 2024.

[5] LeMaterial. LeMat-Bulk: aggregating and de-duplicating quantum chemistry materials databases[J]. arXiv, 2025.

[6] Elkan C, Noto K. Learning classifiers from only positive and unlabeled data[C]//Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2008: 213-220.

[7] Bekker J, Davis J. Learning from positive and unlabeled data: a survey[J]. Machine Learning, 2020, 109: 719-760. DOI: 10.1007/s10994-020-05877-5.

[8] Bridging the synthesizability gap in perovskites by combining computations, literature data, and PU learning[J]. arXiv:2510.06166, 2025.

[9] SynCoTrain: a dual classifier PU-learning framework for synthesizability prediction[J]. arXiv:2411.12011, 2024.

[10] Gelman A, Hill J. Data analysis using regression and multilevel/hierarchical models[M]. Cambridge University Press, 2006. DOI: 10.1017/CBO9780511790942.

[11] Liu T Y. Learning to rank for information retrieval[M]. Springer, 2009.

[12] Qiu T A, Carroll M, Allen C. Truthfulness despite weak supervision: evaluating and training LLMs using peer prediction[C]//International Conference on Learning Representations, 2026. arXiv:2601.20299.

[13] Zeni C, Pinsler R, Zügner D, et al. A generative model for inorganic materials design[J]. Nature, 2025, 639: 624-632. DOI: 10.1038/s41586-025-08628-5.

[14] Kang P, Sun Y, Li Z, et al. CrystalJev: calibrated foundation-model probabilities decide what to compute next in materials discovery[J]. arXiv:2610.06985, 2026.

[15] Noh H, Na G S, Pan E, et al. CondMSP: condition-informed and resource-aware inorganic materials synthesis planning[J]. arXiv:2610.15603, 2026.

[16] Chen L, Zaharia M, Zou J. FrugalGPT: how to use large language models while reducing cost and improving performance[J]. arXiv:2305.05176, 2023.

[17] Raccuglia P, Elbert K C, Adler P D F, et al. Machine-learning-assisted materials discovery using failed experiments[J]. Nature, 2016, 533: 73-76. DOI: 10.1038/nature17439.

[18] Prein T, Pan E, Jehkul J, et al. Language models enable data-augmented synthesis planning for inorganic materials[J]. arXiv:2506.12557, 2025.

[19] Guo C, Pleiss G, Sun Y, et al. On calibration of modern neural networks[C]//International Conference on Machine Learning. PMLR, 2017: 1321-1330.

[20] Angelopoulos A N, Bates S. A gentle introduction to conformal prediction and distribution-free uncertainty quantification[J]. arXiv:2107.07511, 2021.