学校：_____

硕士学位研究生

选题报告及文献综述

论文题目：面向合金配方辅助设计的领域小模型选择性蒸馏与知识增强生成方法研究

指导教师：_____

单　　位：_____

姓　　名：_____

学　　号：_____

专业名称：_____

入学时间：_____

填报日期：_____

目　录

1 选题背景、研究目标与意义
1.1 选题背景
1.2 研究目标与任务定位
1.3 选题意义
2 国内外研究现状与本课题切入点
2.1 材料语言模型与合金生成
2.2 知识蒸馏与领域小模型适配
2.3 指令数据构造与教学样本选择
2.4 检索增强与受约束生成
2.5 研究定位与可延伸空间
3 研究内容与拟采用的方法
3.1 任务范围与总体方案
3.2 证据可追溯的教学数据构造
3.3 学生失误感知与约束覆盖联合的选择性蒸馏
3.4 条件可比的证据选择与约束一致生成
4 拟创新点与研究方案
4.1 拟创新点及其证据要求
4.2 数据与可用资源
4.3 实验设计与公平比较
4.4 指标、接近标准与应用价值验证
4.5 技术路线与阶段衔接
5 可行性、风险与预期成果
5.1 资源与实施可行性
5.2 主要风险及处理边界
5.3 预期成果与完成标准
5.4 数据管理、授权与研究诚信
6 时间安排
参考文献

1 选题背景、研究目标与意义

1.1 选题背景

材料配方设计需要把性能需求、允许使用的原料、成分范围和已有实验经验联系起来。语言模型能够理解自然语言要求，组织文献证据，并与计算工具协同完成候选提出与修改。LLMatDesign 已展示根据人类指令修改材料、调用工具评价并迭代调整的辅助设计范式[1]；合金领域的研究进一步表明，开源语言模型可以经过任务微调和偏好学习生成目标类别的候选成分[2]。因此，本课题不以“首次把语言模型用于材料设计”为立题依据，而是在已有应用基础上研究其本地化与任务能力迁移。

实际使用中的困难不只在于模型能否给出一份答案。配方记录可能位于内部数据库中，检索证据需要保留来源，模型与工具版本需要可控制，使用者还需要在多次修改要求后得到格式一致、便于复核的候选。若系统依赖外部接口，配方和实验记录的传输需要满足授权条件；若完全使用未经适配的本地小模型，则可能出现忽略锁定项、混用比例单位、错误套用不同条件的记录和生成无依据性能数值等问题。这些是本课题拟检验并改善的任务失误，不预先视为所有模型必然存在的事实。

领域适配为解决上述问题提供了方法基础。LLaMat 通过继续预训练与任务微调建立材料领域模型，说明专门化训练具有研究价值，但其大规模训练不是单人课题需要复现的路径[3]。AlloyGPT 用结构化文本学习合金组成与性质的关系，表明配方生成可以被组织为语言建模任务[4]。针对小模型的知识蒸馏、参数高效微调和检索增强生成，则为资源受限条件下的领域应用提供了可借鉴的方法[8][9][19][20]。

本课题据此选择“本地模型辅助形成合金配方方案”这一应用，而不承担通用材料基础模型预训练。研究重点是：有限教学数据应怎样构造和选择，小模型怎样使用证据，以及怎样在明确约束下生成可复核的候选。合金是具体应用场景，计算机方法的增量主要体现在教学数据选择、证据组织和约束生成，不以发明新的材料机理或相形成判据为目标。

1.2 研究目标与任务定位

总体目标是构建可在本地运行的合金配方辅助设计模型，通过选择性任务蒸馏与知识增强，改善同一本地底座的任务表现，并检验其与指定教师大模型的质量差距是否能缩小到预先确定的可接受范围。这里的“接近”只针对限定

任务、固定资料与工具条件，不指获得教师的全部知识，也不预先承诺一定达到该目标。

典型场景为：研究者给定合金类别、允许元素、比例范围、可选的原始配方及一种主要性能偏好，系统提供若干候选成分、修改说明和参考证据。例如，用户希望在已有配方基础上降低某元素比例、保持另一元素不变且不增加新元素，系统应执行明确的成分约束，并说明相关性能信息来自哪条记录、什么测试条件。对仅表达“更便宜”“更强”等模糊偏好的要求，模型应保留偏好或请求补充数值，不能擅自变成具体比例上限。

研究的主要验证任务是“有来源依据的候选形成与配方修改”，输出不是一般知识问答，也不是仅从固定目录返回编号。新生成配方可以作为待验证建议，但其性能不能由教师自评、经验判据通过或引用相近成分文献直接证明。已报道配方的观测值、模型估计值和未经验证的目标值在输出中分别标注。

1.3 选题意义

应用意义：减少方案准备中的重复劳动。 配方研究中的资料筛选、条件核对、成分改写和结果整理可以被拆解为明确操作。AlloyLens 的专家参与案例表明，交互筛选、局部敏感性分析和多目标取舍具有实际应用背景[5]。本课题拟将其中部分方案准备工作转化为本地辅助能力，交付带证据和约束检查结果的候选，而不把“缩短全部研发周期”或“提升真实合成成功率”作为未经验证的承诺。应用收益将通过候选可用性、人工修订量与任务耗时检验，不能由系统演示效果代替。

部署意义：使领域能力在本地可保存、可控制、可复用。 模型权重、检索索引与数值工具在使用阶段均可位于本地，内部配方不必为了完成一次任务而发送到外部接口。模型版本与资料快照可冻结，适配结果可在后续任务中复用。私有化不是自动实现的属性，需要对模型调用、向量化和外部工具请求逐项检查。训练阶段若使用云端教师，只处理公开或明确获准上传的数据；本地运行仍有设备、维护和训练摊销成本，不宣称必然比低价 API 更便宜。

方法意义：把有限资源转化为可研究的数据选择问题。 成熟蒸馏方法已经能够向学生传递任务示范，LESS、DEITA、D3 和 LASER 也表明数据选择本身是活跃研究方向[13][14][15][16]。本课题拟在这些方法基础上做任务化改进：用可以核验的约束失误表示学生薄弱环节，并用约束组合覆盖控制教学样本组成，避免把自由生成中的合理答案差异误判为难度。研究问题是同样教学预算下能否学得更有效，而不是简单宣称“训练越多越好”。

研究价值：形成从教学样本到部署输出的一致证据链。 若训练数据强调来源与适用条件，而推理时只输入无条件的相似文本，模型仍可能错误迁移性能结论。本课题将资料来源、比例单位和约束状态作为教学与推理共用的信息，研究它们能否降低条件混用与无据生成。该价值需要通过消融实验验证，不把使用 LoRA、RAG 或结构化输出本身分别计为创新。

2 国内外研究现状与本课题切入点

2.1 材料语言模型与合金生成

LLMatDesign 将自然语言理解、材料修改和工具评价组成迭代流程，为辅助设计提供了工程参考[1]。针对 BCC/B2 合金的研究利用 LLaMA、Gemma 和 OLMo 等开源模型，通过热力学计算反馈构造偏好数据并进行直接偏好优化[2]。这说明本地开源模型用于合金生成已有前作，“本地部署”不能作为与该研究的唯一差异。其部分偏好数据依赖商业热力学资源，复现实验需要区分公开代码、公开成分数据与受限计算数据，不能将它写成完全不可复现。

LLaMat 面向材料研究的多种文本与结构任务进行大规模领域适配[3]；AlloyGPT 同时研究合金正向预测与逆向生成[4]。二者为领域建模提供依据，但其训练规模、数据构造和可获取资源不能不加区分地用于本课题预算。近期 MaterEval 研究把专家规则转化为知识增强偏好信号，使小型开源模型在高熵合金判断上改善并接近特定闭源模型[6]。它主要研究候选评价，而本课题研究受需求约束的候选提出与修改；两者有关联，不能把评价任务的结果直接当作生成任务的效果保证。

已有工作表明研究路线可以延续，尚不能说明特定小模型已经达到应用要求。本课题在成熟辅助设计范式内研究小模型学习效率与证据使用方式，不依赖“材料领域尚无人做过”的空白声明，也不把既有商业模型成绩直接当成不同数据划分下可比较的基线。

2.2 知识蒸馏与领域小模型适配

知识蒸馏通过教师监督向更容易部署的学生传递能力，其思想早于当前大语言模型[8]。Distilling Step-by-Step 利用教师提供的解释性监督改善任务小模型[9]；Orca 2 强调小模型需要适合自身能力的解题策略，而非机械复制教师行为[10]。这些结果支持任务化教学，但其 NLP 基准结论不等于材料配方任务已经有效。

MiniLLM 研究能够访问教师分布时的蒸馏目标与优化方式[11]。实际使用商业 API 往往只能获得文本输出，因此本课题主线采用基于教师示范的序列级任务蒸馏，再用监督微调学习证据标识、结构化操作及候选输出，不假定可取得教师全词表 logits。教师只提供简短、可检查的操作说明和证据引用，不要求获取其内部隐含推理过程。

LoRA 冻结底座并训练低秩适配参数，QLoRA 进一步结合量化降低微调显存需求[19][20]。这些方法用于控制训练成本，不作为本课题发明的新算法。拟选择许可适合研究与本地部署的开放权重模型，例如 Qwen3 中的小规模稠密模型[21]，具体型号、运行模板与版本将在预实验中固定，不以某个品牌作为论文贡献。

近期 Zhang 等提出 INCAR-SLM，将经过领域微调的小模型与确定性后处理程序 VASPGuard 结合，用于从计算要求和晶体结构生成 VASP 的 INCAR 参数文件[25]。作者在 INCARBench 上报告，该组合在所采用的评分协议下优于其测试的通用大模型，并分别比较了微调与后处理的贡献。这为“领域适配负责学习任务行为、检查器处理可确定规则”的分工提供了相关依据，但它采用参考计算记录监督，并非本课题选择性蒸馏方法的验证。其目标是计算参数文件，合金配方还涉及证据适用条件及新成分的未观测性能，不能直接沿用其评分范围或模型规模结论。本课题借鉴这种分工与归因设计，继续在同证据、同工具条件下检验任务可用性和教师差距，不把他文成绩写成本课题预实验结果，也不预设必须超越某一通用模型。

2.3 指令数据构造与教学样本选择

Self-Instruct 展示了生成指令、过滤无效或相似样本后再训练的基本流程[12]。DEITA 从质量、复杂度与多样性进行数据选择[13]，LESS 用梯度影响近似服务于定向指令微调[14]，D3 联合考虑多样性、难度和可信度[15]。LASER 进一步采用任务分层、专用质量评分及难度度量，并涉及约束生成任务[16]。因此，“困难度加多样性”或“按约束分组”都不能单独声称是新的通用方法。

配方任务的特殊困难在于：同一需求可能有多个合格成分，学生与教师逐词不一致不一定意味着错误；高损失也可能来自合法候选的多样性。拟研究的增量是用任务检查得到的失误类型代替单一文本似然作为薄弱度信号，并以用户约束组合而非仅以文本主题构造覆盖目标。这样的改进是否优于成熟选择方法，须在同一教学池、训练预算和底座上比较；若没有增益，应收回对应创新主张。

2.4 检索增强与受约束生成

检索增强生成将模型参数知识与外部资料结合，有利于提供来源和更新知识[17]。RAFT 在领域问答中训练模型使用相关文档并忽略干扰内容[18]，可为本课题设计“相近成分但条件不同”的教学实例提供方法参考。RAFT 的问答结果不能直接证明生成配方的科学可靠性，必须另行检验实例的条件对应和引用准确性。

PICARD 通过增量解析拒绝不合法的输出扩展，说明结构化任务可以在解码过程中引入明确约束[22]。但其原任务是 SQL，不能直接套用为配方求解算法。合金成分还涉及总量、元素集合、锁定项和不同百分比基准的关联，本课题拟研究将这些约束用于分步比例生成与有限修正，比较它与自由生成后过滤、标准约束解码和确定性求解器的差异。格式正确、数值合法与材料性能达标属于不同层次。

2.5 研究定位与可延伸空间

综合来看，领域适配、小模型蒸馏、数据选择与约束生成均已有成熟研究。可延伸的问题是：在可检查的任务约束下，学生到底应学习哪些示范，以及训练获得的证据使用方式能否在本地检索场景中保持一致。本课题拟围绕这一问题提出三个相互衔接的改进，而不是用组件数量支撑创新性。

与材料专用基础模型相比，本课题不进行海量文献继续预训练；与物理奖励驱动的合金生成相比，不以证明经验描述符等价于 CALPHAD 为前提；与通用教学样本选择相比，重点比较可核验失误与约束组合覆盖的增量；与普通 RAG 系统相比，研究学生的证据使用训练和约束执行，而非建立另一个知识问答界面。近期 HEA-Bench 明确将经验相规则定位为弱筛选而非相预测[23]，故此类工具只作为可选的辅助诊断，不生成真实可合成性标签。

3 研究内容与拟采用的方法

3.1 任务范围与总体方案

研究先限定合金成分层面的辅助设计，不生成完整晶体坐标，不联合优化通用工艺路线，也不保证高温性能或 BCC/B2 相形成。输入包括自然语言要求、允许元素、原始配方及必要的条件；输出包括候选成分、约束执行结果、参考记录和修改说明。主任务优先使用多主元合金公开记录，在资料完整子集上构造“依据可见记录提出候选”和“给定配方按限制修改”的工作任务。

设需求为 u、数值硬约束为 C、允许检索的本地资料为 E，学生模型为 S。拟构建的系统执行“需求结构化→检索条件可比的实例→生成候选及引用→数值检查与有限修正→输出候选表”。模型学习理解要求、选择证据与提出操作，数值工具处理明确的算术与可行性检查。若用户要求本身矛盾，返回可核验的冲突项，由用户决定是否放宽；模型不能自动解锁或修改硬限制。

用轻量任务本体统一表达元素、成分、比例基准、测试条件、来源和约束关系。其作用是提供可执行语义：元素比例和为单位总量，锁定项在后续修改中保持一致，性能值必须绑定测量或预测类型及条件。本体不被当作自动保证科学正确性的证明，类型化决策模型也不设为必须增加的独立模块。

3.2 证据可追溯的教学数据构造

首先，将允许使用的资料组织为“成分—状态—测试—性能—来源”记录。Borg 等发布的 MPEA 数据包含成分、工艺粗标签、相结构、测试温度、拉伸或压缩类型等信息[7]。这些条件不能省略后再把记录间差异当作噪声。已有约两万篇全文库作为潜在扩展资源，其合金覆盖、字段质量和使用权限尚未审计，不将其全部条目直接计为本课题训练数据。

其次，先按来源论文、重复记录和近同成分关联分组，再划分训练、开发与测试。只在训练分区内构造教师示范。示范包含需求解析、引用记录编号、成分修改操作、约束检查结果及最终候选；同一记录可形成不同要求，但所有派生任务属于同一数据分区。原子百分比与质量百分比分别记录，转换使用明确元素原子量，不直接相互复制。

最后，通过约束扰动构造组合任务，例如在同一基础任务中分别增加元素上限、锁定项或禁止新增元素。扰动后必须重新生成或重新检查答案，不能只改需求文本。设 q(d) 为教学样本的质量准入标记：来源存在、字段对应、显式约束通过、无伪造性能值时才进入训练候选池。该准入检查只确认可检查项目；证据是否真正支撑推荐还需人工抽查，不能把引用存在等同于语义支持。

教学数据区分“观测支持型”与“探索建议型”。前者的性能陈述必须回到具体记录，后者只允许教师提供候选与编辑说明，不能把相近材料观测值转移给新配方。训练主线优先使用前者及可确定验证的编辑操作；探索型示范的数量、用途和人工核验比例单列。不得把教学样本扩增数量等同于独立材料实验数量。

3.3 学生失误感知与约束覆盖联合的选择性蒸馏

本部分是拟研究的主要小算法改进。先用统一的小规模种子样本对底座进行预热，或在未适配底座上执行同一诊断任务，得到学生对候选教学任务的输出。用任务检查器记录失误向量，包括比例总量、锁定项、元素集合、单位、已知条件对应及来源引用错误。无法自动判断的语义项目标记为未知，在评分中不冒充正确或错误。生成失败和解析失败按预先规定规则计入，不能因无法评分而排除困难样本。

设 e(d) 为样本 d 的可核验失误分数，h_j(d) 表示该样本是否覆盖第 j 类约束组合，n_j(A) 表示已选集合 A 的覆盖次数。先计算边际效用 G(d ∣ A)=αe(d)+βΣ_j w_j h_j(d)/(1+n_j(A))−γR(d,A)，仅对通过质量准入且 G(d ∣ A)>0 的样本，计算成本归一化得分 Score(d ∣ A)=G(d ∣ A)/c(d)。其中 R 为与已选样本的冗余度，c 为教学 token 成本与训练候选池中位成本的比值，并设正下限，避免极短样本取得异常高分。先剔除 q(d)=0 的样本；e(d) 按可检查失误项目的加权均值计算，权重与缺失项目处理方式在开发阶段固定；冗余度映射至 $[0,1]$，覆盖权重满足 w_j≥0 且 Σ_j w_j=1，使覆盖项不超过 1。参数 α、β、γ 非负且和为 1，排除 α=β=0 的退化配置，主实验从步长为 0.25 的有限网格中选择，以开发集的主要任务得分为依据，在相同预算上限下确定；并列时按事先约定的参数顺序决定。候选网格、失误权重、来源上限与成本下限均在测试前冻结并公布，不根据测试效果反复修改。

每次从满足质量、来源限制及剩余 token 预算的正效用样本中选取得分最高者，更新覆盖计数；没有这样的样本时立即停止，不用零效用或负效用样本填满预算。预算是上限而非必须填满的样本条数，各方法报告实际选中条数与有效训练 token；不足一个样本的剩余预算不通过复制样本补齐。若所提方法提前停止，则把主比较准确称为“相同预算上限”，并补充在其实际有效训练 token 附近的基线预算匹配比较，匹配容差在开发阶段预定，报告剩余差额；不将实际训练量不同宣称为严格等 token。若没有新增样本，保留选样前的模型（预热模型或未适配底座）并报告，不声称完成了新增蒸馏。除开发集选定配置外，另报告相邻网格配置，以及失误、覆盖或冗余项分别去除时的结果，检验收益是否依赖极窄参数设置。敏感性是拟检验问题，当前不预先声称结果稳健；所有基线获得事先限定、可比较的调参机会，额外诊断与选参成本单列。该式是待检验的启发式，不声称无条件的次模近似保证。

与 D3、DEITA 及 LASER 的差别不在于再次相加若干分数，而在于薄弱度的可执行定义和覆盖单位：不以“学生没有复述教师答案”判错，允许多个合法配方；不只覆盖自然语言主题，而覆盖不同约束及其组合。约束检查器与任务标签也提供训练和部署共用的接口，使数据选择直接针对实际操作错误。若该设计与已有专用评分方法效果相同，须据结果说明其边界，不能仅换术语宣称新方法。

在相同底座上使用相同监督目标和 QLoRA 设置训练，优先采用一个冻结选择批次，减少反复诊断成本；若资源允许，再加入一次基于新学生的重选。示范中的简短操作序列与最终输出共同监督，引用标识和数值字段按统一格式表达。若只在已生成的教师池中挑选，本方法节省的是学生训练预算，不自动节省前期教师调用费用；教师生成、学生诊断和选样开销均需计入总成本。

3.4 条件可比的证据选择与约束一致生成

检索以语义和成分相似为起点，同时保留测试类型、温度、粗工艺及来源信息。性能记录不可比时不得合并成一条通用结论；可作为编辑背景的实例与可直接支持性能数值的证据分开处理。缺失关键条件的记录标注为不确定，不因缺失就判定材料不可行。

在固定输入 token 预算下，拟从初检实例中选择既覆盖用户要求又较少重复的证据组合，并与普通 Top-k、标准去冗余检索及条件过滤方法比较。教学阶段同时提供相关实例和“成分相近但条件不适用”的干扰实例，让学生学习何时可以引用、何时只能作背景。证据重排和样本选择分别消融，防止把检索改善全部归给训练算法。

生成采用“元素集合→整数比例份额→引用与说明”的分步表示。统一比例精度后，给定前缀和剩余变量上下界，检查剩余总量能否被合法分配；若不能，则拒绝相应扩展或调用数值工具重新分配。连续比例的离散步长在开发集冻结，并报告舍入容差。不会因整段文本投影后数值合法，就继续保留已经不对应的解释和性能陈述；发生比例修正后必须更新修改说明和证据支持标记。

对一般非线性性能要求，本体与区间检查不能给出完全可行性证明。性能模型仅输出带版本和适用范围的估计，其评分不作为唯一训练真值和科学验证。无解诊断区分“数值硬约束已证明冲突”与“有限搜索预算内未找到候选”，不将后者写成不存在材料解。

4 拟创新点与研究方案

4.1 拟创新点及其证据要求

拟创新点一：约束扰动与证据绑定结合的任务蒸馏数据构造。 在一般指令扩增基础上，使每次要求变化对应重新核验的配方操作，并保留来源、条件和“观测 / 预测 / 建议”类型。拟解决教师示范表面合理但不能执行、不能回溯的问题。创新层级是任务化数据方法，不是发明自生成指令；通过来源错误、约束错误、人工抽查质量及相同规模数据训练后的任务效果验证。在数据构造消融中，分别移除约束扰动或显式证据绑定，与完整构造比较，保持来源分区、训练 token 预算及下游检索与生成设置一致；该实验与共用教学池的选样比较分开。

拟创新点二：可核验学生失误与约束组合覆盖驱动的预算选样。 DEITA 综合质量、复杂度与多样性，D3 采用不确定性相关难度与可信度评分，LASER 已包含任务分层和专用质量评分[13][15][16]；本课题不将它们笼统描述成只用困惑度，也不宣称首次采用任务检查。拟改进的是面向配方辅助生成的失误与覆盖定义：用总量、锁定项、单位和条件引用检查区分“真的做错”与“合法答案不同”，按约束组合的未覆盖程度控制教学组成，并约束来源集中与教学 token 成本。通过同池、同预算下替换失误信号和覆盖单位的对照，检验收益是否来自这些设计而非分数加权本身。必须对比 D3 / DEITA 类方法、LASER 类任务分层、随机和单一困难度选择，并报告选择与调参开销。若不能优于合理对照，不将该项作为已验证贡献。

拟创新点三：教学与推理共用约束状态的检索增强分步生成。 将教学中学习的证据类型、锁定项和剩余配比状态用于本地推理，限制局部修正后出现解释失配。拟解决“训练会按要求作答，部署却因证据变化和数值修补而失效”的一致性问题。与标准 RAG、生成后过滤、统一约束解码及相同数值求解器对照，检验合法性、多样性、证据对应及总开销。

上述三项是相互衔接的拟研究改进，并非已证实的三个突破。主要算法贡献集中于第二项，第一、三项构成其可靠教学与应用条件。私有化部署、LoRA、量化、使用本体以及系统界面本身均不另行计为算法创新。

4.2 数据与可用资源

主线优先使用已经确认可取得的公开 MPEA 数据及其许可允许的来源信息[7]。当前固定版本审计含 1,545 条记录、630 种归一化成分和 265 个 DOI；其

中室温拉伸屈服强度子集只有 287 条记录、91 种成分，室温铸态硬度子集为 254 条记录、233 种成分。此处室温按数据值 20—30 ℃定义，粗工艺不等于完全相同材料状态。这些统计只说明预实验载体存在，不证明足以训练通用性能预测器。

首版应用任务优先围绕资料较充足的硬度记录开展证据支持型候选提出，性能条件不足时不强行附加精确性能目标。主测试保留需要区分证据适用条件的任务，纯算术配比编辑作为辅助结果；真正新配方的硬度不由文本生成结果直接认定。若具备许可与下载条件，可选用 SciVis 再生铝合金模拟数据扩展任务规模[24]，但它不是高熵合金实测数据，正式使用前须核对具体版本、字段和缺失值，不作为当前必需前提。

数据到任务的规模规划如下。前两行是已保存审计的记录数量，后两行是待实施的任务计划，不能相互混用。室温铸态硬度子集含 55 个唯一 DOI，并不是全部资料的 265 个 DOI；两者都不等于完全独立的实验数。

层级	已核实资料或计划规模	使用与边界
MPEA 主资料	1,545 条记录、630 种成分、265 个 DOI	用于资料审计与可用字段筛选，不将全部记录混成相同条件的性能标签
首版硬度子集	254 条记录、233 种成分、55 个 DOI	测试温度字段为 20—30 ℃、粗工艺为 CAST 且有硬度值，详细测试条件仍需核验
预实验教学池	计划约 300—1,000 个合格任务	仅由训练分区产生，每条基础记录先限制至不超过 8 个派生任务，并限制单一来源集中；不足计划数量时如实缩小，不复制凑数
开发与测试任务	由各自来源关联组独立构造	每条基础记录先构造 1—3 个任务；实际记录数、DOI 数、关联组数和任务数在首次划分后报告，目前不填伪造的实测数

关联组划分以约 70% / 15% / 15% 的训练、开发、测试记录比例为规划参考，同组不可拆分，实际比例允许偏离并须报告。划分后先确认每区是否有足够的来源组和可比较任务；若不能支撑稳定的留出比较，扩大获准资料或收紧研究结论，不以增加同记录改写次数代替独立来源。教学池数量与训练 token 分开记录，先在实际可用的小池上做等预算方法验证；更大指令规模只有在新增资料审计通过后才扩展。

已核实的参考资源包括 LLMatDesign 的公开实现、BCC/B2 研究的部分公开成分和训练代码，以及 Qwen3 等开放权重底座[1][2][21]。AlloyGPT 权重或相关数据的获取受许可和申请条件影响，不绑定为开箱即用基线[4]。不要求从头复

现 LLaMat 继续预训练，也不要求采购 Thermo-Calc。需要使用公开数据的项目许可、基础模型许可与教师服务的数据使用条件分别核对，不能用代码开源替代数据授权。

4.3 实验设计与公平比较

设置来源关联组互斥的训练、开发、测试三部分，先划分再做任务扩增。独立教师示范池仅由训练资料产生；选样权重、精度、修正次数和评价规则在开发集冻结；测试任务只作最后报告。性能字段、来源标签和目标配方的泄漏检查独立进行。同一组基础配方的不同自然语言改写不能跨区，必要时增加留出元素组合或相近成分簇的压力测试。

设两类明确区分的测试。第一类为“可见证据支持的辅助任务”：向各方法提供相同且许可允许的测试资料，检查其是否能提出有对应证据且满足要求的候选；这是有资料可用的应用，不把检索到测试记录本身伪装成未知性能预测。第二类为“隐藏目标记录的回放任务”：隐藏目标论文和重复记录，以已知观测标签辅助检查候选恢复或排序；只有候选能规范匹配观测记录时，才计入观测性能支持，未匹配候选标为未验证，不当作实验失败。两类结果分开报告。

基础对照包括本地底座直接生成、普通 RAG、本地常规教师蒸馏、选择性蒸馏及完整知识增强方案。核心选样实验使用相同教学池、相同底座和训练 token 预算，比随机选择、困难度选择、覆盖选择及成熟质量—多样性选择；若 LESS 成本适合，则加入梯度选择对照。全量训练只作额外预算上界参考，不宣称与等预算子集比较完全公平。种子预热与诊断开销在各组使用一致设置，选样计算成本计入总账。

为检验语言模型是否只承担无增益外壳，加入“同一需求解析结果＋传统约束优化器”对照。在资料条件和数值工具一致时，比较模型在实例组织、操作选择与说明生成方面是否有实质收益。对照也允许使用暖启动，不人为限制其候选复用或数值求解能力。对一般投影、取整和配比修正的收益不全部计为模型学习效果。

教师比较冻结一个明确的服务版本、提示、输出预算和运行日期。先在统一证据与工具下比较系统效果，再单列无工具模型表现；只允许学生多用工具而教师不能用工具的比较，必须标为部署方案比较而非模型能力比较。预先记录教师调用失败和重试，训练阶段与最终测试阶段费用分开，不预设“大模型总比小模型慢”或“小模型总比 API 便宜”。

4.4 指标、接近标准与应用价值验证

主要任务指标为需求级的“约束及证据双合格率”，仅统计在评测前由构造协议与独立检查确认数值可行、输入完备且存在足够适用证据的候选形成或编辑任务。任务资格依据冻结的输入、参考资料和规则确定，不能根据某个方法是否成功检索或输出而改变分母；资格不确定的任务单列，并报告纳入与排除数量。在给定输出候选数量和生成预算下，至少提出规定数量的不同候选，所有明确硬约束通过，候选选择或编辑理由对应到适用记录及其支持范围，观测型性能陈述可对应具体测量记录，才计为合格。探索型候选即使没有冒充实测性能，也不能仅凭数值合法计入主任务合格；缺乏适用证据支持的建议单列报告。另报逐候选合法率、证据错误率、候选重复率、修改幅度、修正次数及总生成量，避免仅靠大量采样提高成功率。

数值约束冲突、证据不足和需要澄清的需求单独构造与报告，不混入上述主分母。对能由数值求解器确认的冲突，检查冲突识别及解释正确率，并报告可行任务的误拒率；对证据不足或输入不完整，核验其是否恰当地标注缺失或请求澄清。有限搜索未找到、检索未命中和输入含糊均不算已证明无解。所有任务类别、证据支持规则、缺失处理和人工裁定协议在开发阶段固定并用于全部方法，教师与学生的主质量差距也只在相同主任务集合上计算。

“接近教师”采用任务质量差值而非文本相似率。设 Q_T 和 Q_S 分别为教师与学生的主要任务得分，报告 Q_T-Q_S 的配对差值及不确定区间。可接受差距 δ 与最低可用水平 Q_min 在开发阶段依据实际任务需求确定，测试前锁定；只有差距的区间上界不超过 δ，且学生达到 Q_min 时，才在相应任务范围内使用“接近”表述。无法确定具有实际意义的 δ 时，只报告差距，不宣称已达到可接受水平。教师自身若质量不足，接近教师也不代表可用。

按来源论文或基础任务组进行配对重采样，不能把同一配方的几十次改写当作独立实验。正式训练对核心对照采用多个随机种子，重复数量在预实验资源评估后固定。主对照与探索分析分开，报告效应方向和区间，而不是仅用单次最好值或统计不显著证明等效。

应用价值设置两层证据。可直接核验的是每次获得合格候选所需的重试、字段修正、查证步骤和机器运行开销；涉及“人工时间节省”的结论则需要用户任务试用。若能获得材料研究者参与，采用同任务、交叉顺序和隐去方案标签的结果复核，记录用时与修订量；若无法组织合适使用者，只报告离线操作负担与技术指标，不宣称已经证明产业效率提升。性能模型或经验规则的通过率仅作辅助诊断，不能替代独立实验成败或高温性能验证。

4.5 技术路线与阶段衔接

技术路线为：资料版本与任务审计→来源分组和数据隔离→教师示范构造及可核验项目过滤→学生诊断与约束覆盖选样→QLoRA 任务蒸馏→条件可比的本地检索→分步候选生成及有限修正→与教师及本地强基线比较。教学与推理共用约束状态和来源类型，最终输出模型适配权重、知识库版本和候选表。整体流程见图 4-1。

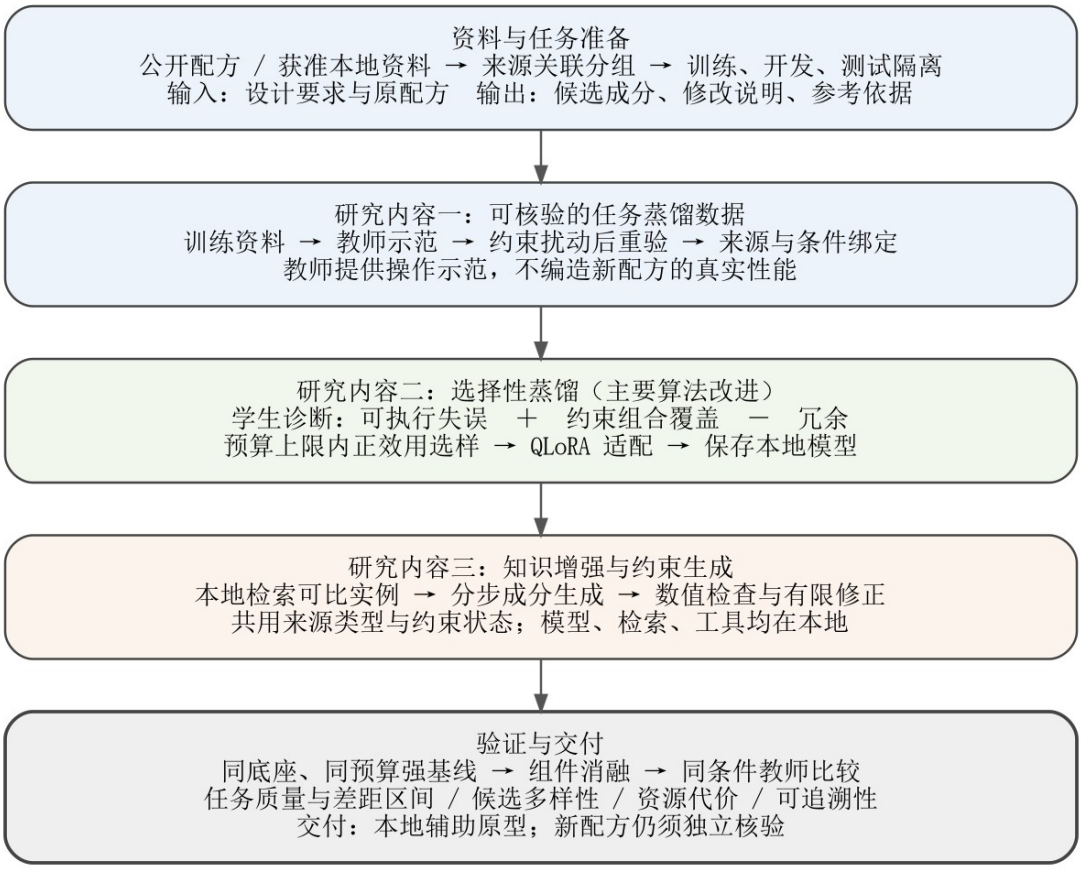


图 4-1 技术路线图

5 可行性、风险与预期成果

5.1 资源与实施可行性

在方法层面，序列级蒸馏不要求获得教师内部参数或完整概率分布，LoRA / QLoRA 有成熟实现，研究任务可在单卡条件下先做小规模验证[19][20]。拟以 4—8B 级稠密底座为主要候选，具体选择通过预实验固定，不预先将某个模型的上下文上限、训练速度或显存占用当作普遍保证。教师可通过 API 离线提供公开资料上的教学示范，推理时不依赖该 API。

开题资源按单张 32 GB 左右显卡、64 GB 内存、500 GB 可用固态存储规划；更长输入或更大批次可租用 48—60 GB 显卡。采用量化底座、梯度检查点、小微批次及约 2k—4k token 输入作为预实验设置，而非已实测结果。首轮按 4.2 的约 300—1,000 个合格教学任务规划，以实际训练分区及质量检查后的规模为准。后续若扩展至约 5,000—20,000 条，必须有新增获准资料与覆盖审计支撑，不能仅靠反复改写现有记录实现，也不将该扩展作为本课题必须完成的条件。

训练耗时按“训练 token 数÷实测吞吐×核心对照数×随机种子数”估计，再单列准备与推理开销。教师示范、诊断、检索建库和最终比较的成本分别记录。当前只核实了路线和资源入口，尚未训练本课题模型，不能把通用论文的 GPU 用量或运行时间复制为本课题保证。

5.2 主要风险及处理边界

第一，公开资料对某些合金体系和工艺覆盖不足，可能使系统只会重述热门实例。应限制可比条件和首版任务，报告独立来源、成分与有效标签量，不通过无控制指令扩增掩盖数据稀薄。若用户全文库经审计后不能使用，主线仍以公开结构化记录开展，不临时增加大规模文献抽取作为另一项研究。

第二，教师可能给出错误示范，检查器也只覆盖部分错误。采用来源绑定、数值验证及人工抽查降低风险，保留检查器未覆盖项目；不把多次生成一致、多个模型同意或解释听起来合理当作真值。教师自评可作辅助排序，但不是最终科学证据。

第三，学生失误评分可能偏向表面格式错误，或因采样而波动。需区分错误类别，加入多个固定解码样本的敏感性分析并计入成本；若选择策略仅改善语法而不改善任务质量，不将其宣传为领域能力迁移成功。若样本选择不如随机，保留负结果，进一步判断问题来自信号、覆盖还是数据质量，不能通过更换测试口径消除失败。

第四，约束生成可能以牺牲多样性和候选质量换取合法率。应固定候选数量与总预算，报告多样性和证据质量；若修正器主导结果，单列其收益。对于超出记录条件的新配方，缺少独立计算或实验时只称为候选建议，不把同一评分器训练与评价形成的闭环当作真实验证。

5.3 预期成果与完成标准

预期形成一份具有来源与条件标注的任务教学数据规范、一种学生失误与约束覆盖驱动的样本选择方法、一个经轻量适配的本地生成模型，以及具备本地检索和数值检查的辅助原型。成果应包括版本化实验配置、对照结果和适用范围，而不只是模型文件或界面演示。

完成标准是能够执行限定任务，并用公平对照说明所提改进是否有效、与教师差距多大及部署成本如何。若未达到“接近教师”的标准，应准确说明尚存差距，不能以“本地化已完成”代替方法验证；是否满足学位要求由所在单位依据其规范判断。未来可扩展更多合金体系或真实实验验证，但不把未落实的合作资源纳入当前完成前提。

5.4 数据管理、授权与研究诚信

公开数据按其许可使用并保留来源；内部配方的上传、再训练和公开分别需要授权，不因去掉名称就默认可外发。教师模型服务条款须允许相应教学数据用途；若条款不允许蒸馏，改用许可合适的本地教师或公开教学数据，并重新说明成本。最终部署检查模型、嵌入、重排与工具链是否存在联网传输，不仅检查生成模型一个环节。

本报告为研究计划，教学构造、选样算法、训练与用户试用均尚待实施。报告整理使用 AI 辅助检索、写作与一致性检查，引用已按可访问原始页面核验，但未声称逐篇复现实验或完成系统性文献综述。涉及人员试用时按所在单位要求落实知情同意和数据保护。姓名、单位、导师、经费、利益冲突与作者贡献等个人或项目声明由实际研究者补充，不代为填写。

6 时间安排

时间表以正式启动后八个月为计划周期，不假设具体入学或答辩日期，实际节点由研究者填写调整。

第 1 个月：完成研究资料、许可、来源关联与任务审计；固定首版合金范围、条件字段、教师和学生候选，完成小规模运行与预算估计。

第 2 个月：构建任务本体、教师示范和准入规则；划分互斥数据集并检查派生样本泄漏，完成本地底座及常规蒸馏基线。

第 3—4 个月：实现并固定学生失误与约束覆盖选样方案，完成等预算强基线比较，检查数据选择计算成本及随机性；在开发集确定主要评价和“接近”容许差距。

第 5 个月：完成本地检索、条件过滤、分步生成和有限修正集成，做分组件消融，确认模型学习与数值工具收益的边界。

第 6 个月：冻结正式配置，完成教师比较、来源组留出及约束组合泛化实验；资源和授权具备时组织有限用户任务试用。

第 7—8 个月：整理结果与复现材料，完成论文撰写、局限性讨论与修改，准备学位论文送审和答辩。若资源不足，优先完成主选样对照与本地任务闭环，减少额外模型与外部验证扩展，不删去关键公平对照。

参考文献

[1] Jia S, Zhang C, Fung V. LLMatDesign: Autonomous materials discovery with large language models[EB/OL]. arXiv:2406.13163, 2024. DOI: 10.48550/arXiv.2406.13163.

[2] Ghosh S, Holgate C, Brodnik N R, et al. Preference learning from physics-based feedback: Tuning language models to design BCC/B2 superalloys[EB/OL]. arXiv:2511.12036, 2025. DOI: 10.48550/arXiv.2511.12036.

[3] Mishra V, Singh S, Ahlawat D, et al. Foundational large language models for materials research[EB/OL]. arXiv:2412.09560, 2024. DOI: 10.48550/arXiv.2412.09560.

[4] Ni B, Glaser B, Taheri-Mousavi S M. End-to-end prediction and design of additively manufacturable alloys using a generative AlloyGPT model[J]. npj Computational Materials, 2025. DOI: 10.1038/s41524-025-01768-2.

[5] Li S, Fajardo-Rojas F, Gomez-Gualdron D, et al. AlloyLens: A visual analytics tool for high-throughput alloy screening and inverse design[EB/OL]. arXiv:2511.02133, 2025. DOI: 10.48550/arXiv.2511.02133.

[6] Yu Y, Hu W, Wu X, Qian Q. From blind guess to informed judgment: Teaching LLMs to evaluate materials by building knowledge-augmented preference signals[EB/OL]. arXiv:2605.29555, 2026. DOI: 10.48550/arXiv.2605.29555.

[7] Borg C K H, Frey C, Moh J, et al. Expanded dataset of mechanical properties and observed phases of multi-principal element alloys[J]. Scientific Data, 2020, 7: 430. DOI: 10.1038/s41597-020-00768-9.

[8] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[EB/OL]. arXiv:1503.02531, 2015. DOI: 10.48550/arXiv.1503.02531.

[9] Hsieh C Y, Li C L, Yeh C K, et al. Distilling step-by-step! Outperforming larger language models with less training data and smaller model sizes[EB/OL]. arXiv:2305.02301, 2023. DOI: 10.48550/arXiv.2305.02301.

[10] Mitra A, Del Corro L, Mahajan S, et al. Orca 2: Teaching small language models how to reason[EB/OL]. arXiv:2311.11045, 2023. DOI: 10.48550/arXiv.2311.11045.

[11] Gu Y, Dong L, Wei F, Huang M. MiniLLM: On-policy distillation of large language models[EB/OL]. arXiv:2306.08543, 2023. DOI: 10.48550/arXiv.2306.08543.

[12] Wang Y, Kordi Y, Mishra S, et al. Self-Instruct: Aligning language models with self-generated instructions[EB/OL]. arXiv:2212.10560, 2022. DOI: 10.48550/arXiv.2212.10560.

[13] Liu W, Zeng W, He K, et al. What makes good data for alignment? A comprehensive study of automatic data selection in instruction tuning[EB/OL]. arXiv:2312.15685, 2023. DOI: 10.48550/arXiv.2312.15685.

[14] Xia M, Malladi S, Gururangan S, et al. LESS: Selecting influential data for targeted instruction tuning[EB/OL]. arXiv:2402.04333, 2024. DOI: 10.48550/arXiv.2402.04333.

[15] Zhang J, Zhang C X, Liu Y, et al. D3: Diversity, difficulty, and dependability-aware data selection for sample-efficient LLM instruction tuning[C]//Proceedings of the Thirty-Fourth International Joint Conference on Artificial Intelligence. 2025: 8348-8356. DOI: 10.24963/ijcai.2025/928.

[16] Mirza P, Weber L, Küch F. LASER: Stratified selective sampling for instruction tuning with dedicated scoring strategy[EB/OL]. arXiv:2505.22157, 2025. DOI: 10.48550/arXiv.2505.22157.

[17] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[EB/OL]. arXiv:2005.11401, 2020. DOI: 10.48550/arXiv.2005.11401.

[18] Zhang T, Patil S G, Jain N, et al. RAFT: Adapting language model to domain specific RAG[EB/OL]. arXiv:2403.10131, 2024. DOI: 10.48550/arXiv.2403.10131.

[19] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-rank adaptation of large language models[EB/OL]. arXiv:2106.09685, 2021. DOI: 10.48550/arXiv.2106.09685.

[20] Dettmers T, Pagnoni A, Holtzman A, Zettlemoyer L. QLoRA: Efficient finetuning of quantized LLMs[EB/OL]. arXiv:2305.14314, 2023. DOI: 10.48550/arXiv.2305.14314.

[21] Yang A, Li A, Yang B, et al. Qwen3 technical report[EB/OL]. arXiv:2505.09388, 2025. DOI: 10.48550/arXiv.2505.09388.

[22] Scholak T, Schucher N, Bahdanau D. PICARD: Parsing incrementally for constrained auto-regressive decoding from language models[EB/OL]. arXiv:2109.05093, 2021. DOI: 10.48550/arXiv.2109.05093.

[23] Fieser D, Dewanjee U, Hu A. HEA-Bench: An AI-agent-optimized calculator of high-entropy alloy and oxide descriptors and phase-prediction rules[J]. Materials, 2026, 19(14): 3075. DOI: 10.3390/ma19143075.

[24] Bugelnig K, Requena G. Dataset - SciVisContest - Materials Discovery Challenge - version 2025[DS/OL]. Zenodo, version v3. DOI: 10.5281/zenodo.15189444. 数据说明：https://sciviscontest2025.github.io/data/.

[25] Zhang X, Li J, Shao B, et al. Fine-tuning small language models for reliable VASP INCAR generation[EB/OL]. arXiv:2608.05387, 2026. DOI: 10.48550/arXiv.2608.05387.